

迈向情感支持对话系统

Siyang Liu^{1,2*}, Chuji Zheng^{1*}, Orianna Demasi³, Sahand Sabour¹, Yu Li³, Zhou Yu⁴, Yong Jiang², Minlie Huang^{1†}

¹The CoAI group, DCST, Institute for Artificial Intelligence, State Key Lab of Intelligent Technology and Systems, Beijing National Research Center for Information Science and Technology, Tsinghua University, Beijing 100084, China

²Tsinghua-Berkeley Shenzhen Institute, Tsinghua Shenzhen International Graduate School, Tsinghua University, Shenzhen, China

³University of California, Davis ⁴Columbia University

siyang-ll18@mails.tsinghua.edu.cn, chuji Zhengchn@gmail.com, aihuang@tsinghua.edu.cn

* 同等贡献。† 通讯作者。

摘要

情感支持 (Emotional Support, ES) 是许多对话场景中的关键能力, 包括社交互动、心理健康支持和客户服务聊天。遵循合理流程并使用多种支持技能, 有助于有效地提供支持。然而, 由于缺少设计良好的任务以及有效情感支持对话语料库, 关于如何把情感支持构建进对话系统的研究仍然基本空白。本文定义了情感支持对话 (Emotional Support Conversation, ESC) 任务, 并提出一个基于 Helping Skills Theory (Hill, 2009) 的 ESC Framework。我们构建了一个 Emotional Support Conversation 数据集 ESConv, 该数据集采用 help-seeker 与 supporter 模式, 并带有丰富标注, 尤其是 support strategy 标注。为了确保语料库包含能够展示有效情感支持的高质量对话, 我们在数据收集过程中投入了大量工作: 为 supporter 设计培训课程, 并设置多种质量控制机制。最后, 我们评估了 state-of-the-art 对话模型提供情感支持的能力。结果显示, support strategies 对提供有效情感支持非常重要, 同时 ESConv 有助于训练更具情感支持能力的系统。

1 引言

情感支持旨在降低个体的情绪痛苦, 并帮助他们理解和处理自己所面临的挑战 (Burlinson, 2003; Langford et al., 1997; Heaney and Israel, 2008)。对于那些需要与用户进行日常互动的对话系统而言, 这是一项关键能力 (Van der Zwaan et al., 2012; Zhou et al., 2020)。这一能力尤其适用于包含社交互动 (陪伴用户、鼓励用户)、心理健康支持 (安慰受挫的求助者并帮助其识别问题)、客户服务聊天 (安抚愤怒的客户并提供解决方案) 等设置。近期研究也表明, 人们更偏好能够给出更多支持性回应的对话系统 (Rains et al., 2020)。




Figure 1: An example chat showing effective emotional support (adapted from ESConv) being provided to the help-seeker(left) by the supporter(right). The **support strategies (skills)** used by the supporter are marked in the parentheses before the utterances. The **red bold texts** in the dashed boxes highlight the three stages of our proposed ESC Framework (Figure 3).

研究表明, 提供情感支持并不是一种直觉性的能力 (Burlinson, 2003)。因此, 已有研究提出了相应的流程与会话技能 (Hill, 2009), 以帮助人们通过对话提供更好的支持。这些技能可以在我们收集的、图 1 所示的示例对话中看到。为了识别求助者痛苦的原因, 支持者首先探索求助者的问题。如果缺少探索, 支持者就不太可能理解求助者的经历与感受; 在这种情况下, 如果支持者给出无关建议, 比如“你可以去散步放松一下”, 就可能显得冒犯, 甚至造成伤害。在了解求助者处境的过程中, 支持者可以通过多种技能 (例如 Self-disclosure、Reflection of Feelings 等) 表达理解与共情, 从而缓解求助者的挫败感。在理解求助者的问题之后, 支持者可以提供建议, 帮助求助者应对问题。相反, 如果支持者只是安慰求助者, 却没有启发其采取行动和做出改变, 那么支持者可能无法有效帮助求助者改善情绪。最后, 在该示例对话的数据收集过程中, 求助者报告其情绪强度从 5 降低到 2 (我们的语料库标注了情绪强度; 该示例的详细标注见附录 A), 这表明支持者提供的 ES 是有效的。

尽管 ES 重要且复杂，但由于缺乏任务设计，也缺少能够展示多样 ES 技能使用方式的相关对话语料库，关于数据驱动的 ES 对话系统的研究仍然有限。首先，现有与情绪聊天 (Zhou et al., 2018) 或共情回应 (Rashkin et al., 2019) 相关的研究系统，所返回的消息只是情绪或共情的示例，因此功能有限；它们并不具备许多常用于提供有效 ES 的其他技能 (Hill, 2009)。图 2 展示了这三个任务之间的关系，我们将在第 2.1 节进一步讨论。其次，人们并非天然擅长支持他人，因此已有指南用于训练人类如何更具支持性。若没有受过训练的参与者，现有在线对话数据集 (Sharma et al., 2020a; Rashkin et al., 2019; Zhong et al., 2020; Sun et al., 2021) 并不会自然呈现支持性对话的实例或要素。因此，利用这些语料库的数据驱动模型 (Radford et al., 2019; Zhang et al., 2020; Roller et al., 2020) 在显式学习如何使用支持技能、从而提供有效 ES 方面存在局限。




Figure 2: Emotional support conversations (our work) can include elements of emotional chatting (Zhou et al., 2018) and empathetic responding (Rashkin et al., 2019).

本文定义了情感支持对话 (ESC) 任务，其目标是通过社交互动 (例如同伴、朋友或家人之间的互动) 提供支持，而非提供专业咨询；并提出一个 ESC Framework，该框架基于 Helping Skills Theory (Hill, 2009)，且根据对话系统场景进行了调整 (图 3)。我们通过改编 Hill 的 Helping Skills 会话支持模型中的相关组成部分，谨慎地为对话系统场景设计了 ESC Framework。该框架提出三个阶段 (Exploration、Comforting 和 Action)，每个阶段包含若干 support strategies (或 skills)。为促进情感支持对话研究，我们随后构建了 Emotional Support Conversation 数据集 ESConv，并通过多方面努力确保数据带有丰富标注，同时保证所有对话都是这一复杂对话任务的高质量示例。ESConv 由众包工作者分别扮演 help-seeker 与 supporter 进行聊天而收集。我们基于 ESC Framework 设计教程并训练所有 supporter，同时设置多种人工和自动机制，以确保对话中的情感支持有效。最后，我们评估了 state-of-the-art 模型，并观察到：当使用多种 support strategies 时，系统提供的情感支持有显著提升。对交互式评估结果的进一步分析表明，Joint 模型能够在策略使用方面模仿人类 supporter 的行为。我们相信，本文工作将促进更多数据驱动方法的研究，以构建能够提供有效情感支持的对话系统。

2 相关工作

2.1 情绪对话与共情对话

图 2 直观展示了 ESC、情绪对话与共情对话之间的关系。已有研究表明，emotion 对构建更具吸引力的对

话系统非常重要 (Zhou et al., 2018; Li et al., 2017; Zhou and Wang, 2018; Huber et al., 2018; Huang et al., 2020)。作为情绪对话中的代表性工作，Zhou et al. (2018) 提出 Emotional Chatting Machine (ECM)，其任务是在给定预先指定的 emotion 时生成带情绪的回答。该任务要求在生成回应中准确表达 (指定或未指定的) 情绪。虽然 ES 也可能包含表达情绪，例如快乐或悲伤，但它更广泛的目标是通过使用适当的支持技能来降低用户的情绪痛苦；这与 emotional chatting 有根本区别。情绪聊天只是对话系统的一种基础质量，而 ES 是对话系统有望具备的一种更高层级、更复杂的能力。

另一个相关任务是 empathetic responding (Rashkin et al., 2019; Lin et al., 2019; Majumder et al., 2020; Zandie and Mahoor, 2020; Sharma et al., 2020a; Zhong et al., 2020; Zheng et al., 2021)，它旨在理解用户感受并据此作出回应。例如，Rashkin et al. (2019) 认为，对话模型可以通过识别对话对象的感受来生成更具共情性的回应。有效 ES 自然要求根据 help-seeker 的经历与感受表达共情，这也体现在本文提出的 Emotional Support Framework 中 (第 3.2 节，图 3)。因此，共情回应只是情感支持的必要组成部分之一。除了共情回应之外，情感支持对话还需要探索用户的问题，并帮助他们应对困难。

2.2 情感支持相关数据集

多项工作在社会语境中考虑过情感支持对话，例如社交媒体或在线论坛中的对话 (Medeiros and Bosse, 2018; Sharma et al., 2020b; Hosseini and Caragea, 2021)。Medeiros and Bosse (2018) 从 Twitter 收集与压力相关的帖子和回复对，并将回复划分为不同支持类别。Sharma et al. (2020b) 对 TalkLife 和心理健康 subreddit 中的帖子-回复对进行了标注，标注内容为文本型共情表达的 communication mechanisms (只有 Reddit 部分的数据公开可用)。Hosseini and Caragea (2021) 也从在线支持小组中收集了这类帖子-回复对，并将其标注为需要支持或表达支持。这些语料库中的对话要么是单轮互动 (帖子-回复对)，要么是非常短的对话，这限制了有效 ES 的潜力，因为 ES 往往需要多轮互动 (Hill, 2009)。


2.3 情感支持对话系统

一些传统对话系统曾使用人工编写的规则来提供情感支持回应 (Van der Zwaan et al., 2012; van der Zwaan et al., 2012)。一个较新的系统考虑了基于规则的算法：该算法确定回应中使用的 supportive act，然后从预定义候选列表中选择合适回复 (Medeiros and Bosse, 2018)。另一个旨在提供 COVID-19 应对支持的会话系统，则通过识别用户提到的主题，再以模板中的 reflection 或预定义词典中的消息作为回应 (Welch et al., 2020)。很少有研究关注支持性回应的生成；即便有，范围也较为有限。例如，Shen et al. (2020) 探索了如何通过反映用户输入来生成支持性回应。

3 情感支持对话

3.1 任务定义

当用户处于不良情绪状态时，也许是由于某个具体问题，他们可能会寻求帮助以改善自己的情绪状态。在这种设置下，用户可以被标注一个负面 emotion label e 、一个 emotion intensity level l （例如从 1 到 5），以及一个其正在经历的潜在 challenge。supporter（或系统）需要在对话中使用支持技能安慰用户，以降低其 intensity level。需要注意的是，在对话开始前，用户状态对 supporter 是未知的。在对话过程中，supporter 需要识别用户面临的问题、安慰用户，然后提供一些建议或信息，帮助用户采取行动应对问题。如果在对话结束时用户的 intensity level 降低，那么这场情感支持对话就是有效的；更具体地说，如果 supporter 能够有效识别问题、安慰用户，并提供解决方案或建议，那么对话就是有效的。



Question			
		Can you talk more about your feelings at that time?	do you (15.0), are you (13.8), how (13.7), what (12.3), do (11.5)
Restatement or Paraphrasing		It sounds that you feel like everyone is ignoring you. Is it correct?	is that (8.2), so you (8.2), it sounds (7.1), correct (7.1), so (6.6)
Reflection of Feelings		I understand how anxious you are.	can tell (7.4), understand how (5.8), are feeling (5.1), tell (5.1), understand (4.9)
Self-disclosure		I feel the same way! I also don't know what to say to strangers.	my (15.3), was (10.5), me (10.2), had (9.7), myself (7.8)
Affirmation and Reassurance		You've done your best and I believe you will get it!	its (5.7), thats (5.6), will (5.4), through this (5.1), you will (4.7)
Providing Suggestions		Deep breaths can help people calm down. Could you try to take a few deep breaths?	maybe (7.3), if (6.5), have you (6.4), talk to (5.8), suggest (5.8)
Information		Apparently, lots of research has found that getting enough sleep before an exam can help students perform better.	there are (4.4), will (3.8), available (3.7), seen (3.3), possible (3.3)
Others		I am glad to help you!	welcome (9.6), hope (9.6), glad (7.3), thank (7.0), hope you (6.9)

Figure 3: Overview of our proposed ESC Framework. It contains three stages and suggested support strategies. The procedure of emotional support generally follows the order: ①Exploration → ②Comforting → ③Action (as indicated by the **black** arrows), but it can also be adapted to the individual conversation as needed (indicated by the **dashed gray** arrows). The column of “Lexical Features” displays top 5 unigrams or bigrams associated with messages that use each strategy in our dataset. Each feature is ranked by the rounded z -scored log odds ratios (Monroe et al., 2008) in the parentheses.

阶段。Hill (2009) 提出了支持他人的三个阶段：exploration（通过探索帮助 help-seeker 识别问题）、insight（帮助 help-seeker 进入更深层的自我理解）和 action（帮助 help-seeker 决定采取何种行动来应对问题）。然而，我们注意到，insight 通常需要重新解释用户的行为与感受；对于没有充分支持经验的 supporter 来说，这既困难又有风险。因此，我们将 insight 调整为 comforting（定义为通过共情与理解提供支持）。尽管建议情感支持对话以这三个有序阶段为目标，但在实践中，对话不能遵循固定或线性顺序，而必须适当地适应具体情况。正如 Hill (2009) 所建议的，三个阶段可以灵活调整，以满足 help-seeker 的需求。

策略。Hill (2009) 也为每个阶段提供了若干推荐会话技能。其中一些技能在没有专业监督和经验的对话系统场景中并不合适。例如，一种名为 challenging 的技能指向 help-seeker 未意识到或不愿改变的矛盾之处或非理性信念。此类技能通常需要专业经验，对于普通人来说过于困难。为了将这些技能调整到适合

ESC 任务包含若干子问题：（1）Support strategy selection 与 strategy-constrained response generation。后文实验（第 6.4 节）表明，应用策略的时机与 ES 的有效性相关。因此，生成回应是否符合指定策略非常重要。（2）Emotion state modeling。动态地建模和追踪用户情绪状态十分重要，因为这既关系到动态策略选择，也关系到 ESC 有效性的衡量。（3）支持有效性的评估。除了传统对话评估维度，例如相关性、连贯性和用户参与度，ESC 还提出了新的维度：评估 ES 的有效性。

3.2 ESC Framework

我们提出 ESC Framework，将情感支持的过程刻画为三个阶段，每个阶段包含若干推荐的 support strategies。该框架基于 Hill 的 Helping Skills Theory (Hill, 2009)，并被调整为更适合对话系统场景；其目标是通过社交互动（例如同伴、朋友或家人之间的互动）提供支持，而不仅仅是专业咨询。ESC Framework 中的会话阶段与策略概览见图 3。

对话系统场景，我们从中抽取了七种方法（加上一个“Others”），在本文任务及后续内容中称之为 strategies。每种策略的详细定义见附录 B。

4 数据收集

为促进对话系统中情感支持技能的研究，我们引入 Emotional Support Conversation Dataset，即 ESConv。它由众包工作者以 help-seeker 与 supporter 模式收集。由于这一复杂任务需要高质量对话示例，我们投入了大量工作，以尽可能确保对话中 ES 的有效性。这些努力主要包括：（1）由于提供会话支持是一种必须经过训练才能有效掌握的技能（Burlison, 2003），我们使用 ESC Framework 设计教程并训练众包工作者成为 supporter。只有通过考核的人才被允许参与任务。（2）我们要求 help-seeker 在聊天前完成关于自身问题与情绪的预聊天问卷，并在对话过程中及对话后提供反馈。（3）我们设计并使用多种人工或自动机制，在收集原始对话数据后过滤低质量对话。

4.1 Supporter 专属任务

训练与考核。为了教会众包工作者如何提供有效情感支持，我们使用 ESC Framework 设计了教程。受 7cups (7cups.com) (Baumel, 2015) 启发，我们开发了 11 个子任务 (3 + 8)，帮助工作者学习三个阶段和八种 support strategies 的定义。每个子任务包括一段示例对话节选和一道对应测验题。如第 3.2 节所述，我们也告知参与者，遵循固定顺序并不总是可能的，他们可能需要灵活调整阶段转换。

策略标注。为了鼓励 supporter 在对话中使用 ESC support strategies，并使最终数据集结构化，我们要求 supporter 首先根据对话上下文选择一个他们想使用的合适策略。随后，他们可以写出体现所选策略的话语。如果 supporter 希望使用多种策略提供支持，我们鼓励他们发送多条消息。

聊天后问卷。每场对话结束后，supporter 需要使用五点 Likert scale 评价 seeker 对自身问题描述的详细程度。

4.2 Seeker 专属任务

聊天前问卷。每次对话前，help-seeker 需要完成如下问卷：(1) 问题与情绪类别：help-seeker 需要从 5 个选项中选择一个问题，并从 7 个选项中选择一种情绪（这些选项基于试点数据收集中的对话）。

(2) 情绪强度：1 到 5 的分数（数字越大表示情绪越强）。(3) 情境：用开放文本描述情绪问题的原因。(4) 经历来源：所描述情境是 help-seeker 当前经历，还是基于过往生活境遇。我们发现，75.2% 的对话来自 help-seeker 的当前经历。

反馈。对话过程中，help-seeker 每收到 supporter 两条新话语后，都需要给出一次反馈。反馈以 5 星量表评价 supporter 消息的帮助程度。我们将每场对话分为三个阶段，并计算每个阶段的平均反馈分数。这三个阶段的分数分别为 4.03、4.30 和 4.44，表明 supporter 经过了充分训练，能够有效帮助 help-seeker 感觉更好。

聊天后问卷。每场对话结束后，help-seeker 需要在如下五点 Likert scale 上评价自己的情绪与 supporter 的表现：(1) 情感支持对话之后的情绪强度（与对话前相比降低代表情绪改善）；(2) supporter 对 help-seeker 经历和感受的共情与理解；(3) supporter 回应与对话主题的相关性。

4.3 质量控制

我们使用多种方法确保语料库包含有效情感支持对话的高质量示例。

初步过滤机制。在招募 supporter 角色参与者时，我们最初收到 5,449 名申请者，但只有 425 人 (7.8%) 通过了培训教程。在最初收集的 2,472 场对话中，我们过滤掉了未由 help-seeker 完成的对话，以及少于 16 条话语的对话。该过滤保留了 1,342 场对话 (54.3%) 用于进一步考虑。

Roles	Aspects	Criteria
Supporter (≥ 3)*	Understanding the help-seeker's experiences and feelings (<i>rated by the help-seeker</i>)	>= 3
	Relevance of the utterances to the conversation topic (<i>rated by the help-seeker</i>)	>= 4
	Average length of utterances	>= 8
	Improvement in the help-seeker's emotion intensity (<i>rated by the help-seeker</i>)**	>= 1
Seeker	Describing details about the own emotional problems (<i>rated by the supporter</i>)	not required
	Average length of utterances	>= 6

Table 1: Criteria of high-quality conversations. * denotes that supporters must meet at least two of the three criteria. In **, the improvement of the help-seeker's emotion intensity was calculated by subtracting the intensity after from that before the conversation.

合格对话的自动批准程序。我们精心设计了 auto-approval program，这是数据质量控制中最重要的部分。该程序使用的标准基于两个角色的聊天后问卷结果和话语长度，概括见表 1。这些标准基于初始人工审查结果。附录 D 展示了如何选择这些自动批准标准。计算得到的对话前平均情绪强度为 4.04，对话后为 2.14。这种改善证明 supporter 提供的情感支持是有效的。在少量对话中，help-seeker 未完成聊天后问卷，因此我们为这些对话增加了另一条标准：help-seeker 最后两次反馈分数都必须大于 4。因此，在所有没有聊天后问卷的对话中，只有同时满足标准 (2) 和 (3) 的对话才合格。使用这些质量标准后，收集到的 1,342 场对话中有 1,053 场合格 (78.5%)。

标注修正。为进一步保证数据质量，我们检查并修正了 support strategy 与 seeker 情绪强度的错误标注。(1) 对于 strategy annotation correction，我们要求新的合格 supporter 在必要时审查并修正此前收集对话中的标注，这使 2,545 条话语 (17.1%) 得到审查。对于超过 75% 审查者不同意的标注，我们进行了人工复核，并修正其中 139 条。(2) 根据 auto-approval criteria (表 7)，当 seeker 情绪改善分数小于 1、但其他三项标准满足时，对话仍可能合格。经复核，我们发现这通常是由于 seeker 将负面情绪强度误解为情绪积极程度。我们人工复查并利用其他有用信息修订这些对话的情绪强度，例如聊天后开放题回答和聊天期间的 seeker 反馈分数。在 130 场此类对话中，92% 被修订并纳入语料库。

5 数据特征

5.1 统计信息

1,053 个 ESConv 示例的总体统计如表 2 所示。对话相对较长（平均 29.8 条话语），这表明有效 ES 通常需要多轮互动；其轮数也明显多于此前典型 emotional chatting (Zhou et al., 2018) 或 empathetic dialog (Rashkin et al., 2019) 数据集。

Category	Total	Supporter	Seeker
# dialogues	1,053	-	-
Avg. Minutes per Chat	22.6	-	-
# Workers	854	425	532
# Utterances	31,410	14,855	16,555
Avg. length of dialogues	29.8	14.1	15.7
Avg. length of utterances	17.8	20.2	15.7

Table 2: Statistics of ESConv.

	Categories	Num	Proportion
Seeker's Problem	Ongoing Depression	306	29.1%
	Job Crisis	233	22.1%
	Breakup with Partner	216	20.5%
	Problems with Friends	159	15.1%
	Academic Pressure	139	13.2%
	Overall	1,053	100.0%
Seeker's Emotion	Anxiety	281	26.7%
	Depression	276	26.2%
	Sadness	250	23.7%
	Anger	96	9.1%
	Fear	88	8.4%
	Disgust	32	3.0%
	Shame	30	2.8%
	Overall	1,053	100.0%
Seeker's Feedback	1 (Very Bad)	71	1.1%
	2 (Bad)	183	2.9%
	3 (Average)	960	15.5%
	4 (Good)	1,855	29.9%
	5 (Excellent)	3,144	50.6%
	Overall	6,213	100.0%
Support Strategy	Question	3,109	20.9%
	Restatement or Paraphrasing	883	5.9%
	Reflection of Feelings	1,156	7.8%
	Self-disclosure	1,396	9.4%
	Affirmation and Reassurance	2,388	16.1%
	Providing Suggestions	2,323	15.6%
	Information	904	6.1%
	Others	2,696	18.1%
	Overall	14,855	100.0%

Table 3: Statistics of all the annotations, including the help-seekers' problems, emotions, feedback, and the support strategies.

我们还在表 3 中展示了其他标注的统计信息。也许由于当时 COVID-19 暴发, ongoing depression 与 job crisis 是 help-seeker 最常陈述的问题, 而 depression 与 anxiety 是最常见的情绪。从 help-seeker 的反馈来看, 他们通常对情感支持高度满意, 这进一步表明, 基于 ESC Framework 的培训教程确实帮助 supporter 学会了提供有效 ES。我们发布所有这些标注, 以促进后续研究。

5.2 策略分析




Figure 4: The distribution of strategies at different conversation progress.

词汇特征。我们通过计算 informative Dirichlet prior 的 log odds ratio (Monroe et al., 2008), 为每种策略抽取 lexical features; 具体做法是将每种策略对应的所有 unigram 和 bigram 与其他策略进行对比。我们在图 3 中列出了每种策略的 top 5 短语。这些策略都与某些短语显著相关 (z-score > 3), 例如 Question 与 “are you”, Self-disclosure 与 “me”。

策略分布。我们计算了不同对话阶段中的策略分布。对于总共有 L 条话语的对话, 如果第 k ($1 \leq k \leq L$) 条话语来自 supporter 且采用策略 st, 我们称其位于对话进度 k/L 。具体来说, 我们将对话进度划分为六个区间: $[0, 1] = \bigcup_{i=0}^4 [i/5, (i+1)/5) \cup \{1\}$ 。随后, 对 ESConv 中的所有对话, 我们统计了这六个区间中不同策略的比例, 并分别在六个点 $i/5$ ($i=0, \dots, 5$) 上绘制分布并连接, 最终得到图 4。

supporter 通常遵循 ESC Framework (图 3) 建议的阶段顺序, 但也存在阶段与策略采用的灵活调整。例如, 在对话早期, supporter 通常采用探索性策略, 如 Question。在了解 help-seeker 的处境之后, supporter 倾向于给出自己的意见 (如 Providing Suggestions)。在整个对话中, comforting strategies (如 Affirmation and Reassurance) 都会被使用, 并在消息中保持相对稳定的比例。

策略转移。我们在附录中展示了最常见的 top-5 3-hop / 4-hop 策略转移 (表 6)。这些转移表明, 正如 ESC Framework 教程所训练的那样, supporter 通常会在安慰 help-seeker 之前先提问并探索其处境。

6 实验

我们的实验关注两个关键问题: (1) 带有策略标注的 ESConv 能在多大程度上改进 state-of-the-art 生成式对话模型? (2) 这些模型能否从 ESConv 中学习提供有效情感支持?

6.1 Backbone Models

我们使用两个 state-of-the-art 预训练模型作为被比较变体模型的 backbones。

BlenderBot。BlenderBot (Roller et al., 2020) 是一个开放域会话代理, 使用多种 communication skills 训练, 其中包括 empathetic responding。因此, BlenderBot 应在一定程度上能够为用户提供

ES。我们在实验中使用 BlenderBot 的 small version，因为更大版本存在最大上下文长度 128 的限制；我们发现这一限制会损害模型性能和回应连贯性。

DialoGPT。我们还评估了 DialoGPT (Zhang et al., 2020)，它是一个基于 GPT-2、在大规模对话语料库上预训练的模型。我们使用其 small version。

6.2 Variant Models

以上述每个预训练模型为 backbone，我们构建了如下变体模型。

Vanilla。直接在 ESConv 上 fine-tune backbone model，且不访问策略标注。形式上，设扁平化后的对话历史为 x ，待生成回应为 y ，我们最大化条件概率： $P(y|x) = \prod_{i=1}^{|y|} P(y_i|x, y_{\leq i})$ 。

带策略的变体。为了将策略标注纳入 backbone model，我们使用一个特殊 token 表示每种策略。对于 supporter 的每条话语 y ，我们在该话语前附加相应 strategy token： $\hat{y} = [st] \oplus y$ ，其中 $[st]$ 表示所使用策略的特殊 token。随后，以扁平化对话历史 x 为输入，模型在第一个预测（或指定）的 strategy token 条件下生成回应： $P(\hat{y}|x) = P([st]|x) \prod_{i=1}^{|y|} P(y_i|x, [st], y_{<i})$ 。

在后续实验中，我们研究三种使用策略标注的变体：

(1) Oracle: 在 gold reference strategy tokens 条件下生成回应；(2) Joint: 在预测（采样）的 strategy tokens 条件下生成回应；(3) Random: 在随机选择的策略条件下生成回应。实现细节见附录 C。

6.3 自动评估

为研究在以 BlenderBot 或 DialoGPT 为 backbone 时使用 support strategies 对模型性能的影响，我们比较了上述 Vanilla、Joint 和 Oracle 变体。采用的自动指标包括 perplexity (PPL)、BLEU-2 (B-2) (Papineni et al., 2002)、ROUGE-L (R-L) (Lin, 2004) 以及 BOW Embedding-based (Liu et al., 2016) Extrema matching score。除 PPL 外，指标均使用 NLG evaluation toolkit (Sharma et al., 2017) 计算，并使用 NLTK (Loper and Bird, 2002) 对回应进行分词。

Backbones	Variants	PPL	B-2	R-L	Extrema
DialoGPT	Vanilla	15.51	5.13	15.26	49.80
	Joint	-	5.00	15.09	49.97
	Oracle	15.19	5.52	15.82	50.18
BlenderBot	Vanilla	16.23	5.45	15.43	50.49
	Joint	-	5.35	15.46	50.27
	Oracle	16.03	6.31	17.90	51.65

Table 4: Results of automatic evaluation. The results in **bold** are significantly better than all the competitors (Student’s t-test, p -value < 0.05).

实验有三个主要发现（表 4）。(1) Oracle 模型在所有指标上都显著优于 Vanilla 模型，说明 support strategies 具有很大效用。(2) Joint 模型得分略低

于 Vanilla 模型，因为如果预测策略不同于 ground truth，生成回应就会与参考回应有很大差异。然而，在没有 ground truth label 的情况下，学习预测策略非常重要；我们将在 human interactive evaluation (第 6.4 节) 中进一步考察 Joint 模型表现。(3) BlenderBot 变体始终优于 DialoGPT 变体，说明 BlenderBot 更适合 ESC 任务。因此，在后续人工评估中，我们将重点评估 BlenderBot 变体。

6.4 Human Interactive Evaluation

我们从 Amazon Mechanical Turk 招募参与者与模型聊天。在线测试在与数据收集相同的平台上进行，但 supporter 角色由模型承担。每位参与者与两个不同模型聊天，模型顺序随机，以避免 exposure bias。参与者需要基于以下问题比较两个模型：(1) Fluency: 哪个 bot 的回应更流畅、更易理解？

(2) Identification: 哪个 bot 更深入地探索你的情况，并更有助于识别你的问题？(3) Comforting: 哪个 bot 更擅长安慰你？(4) Suggestion: 哪个 bot 针对你的问题给出了更有建议的建议？(5) Overall: 总体而言，你更喜欢哪个 bot 的情感支持？其中 (2)、(3) 和 (4) 对应 ESC Framework 的三个阶段。

Joint vs.	w/o ft		Vanilla		Random	
	Win	Lose	Win	Lose	Win	Lose
Fluency	71[‡]	24	52[†]	35	53[†]	35
Identification	65[‡]	25	50	34	54[†]	37
Comforting	75[‡]	20	54[‡]	34	47	39
Suggestion	72[‡]	21	47	39	48[†]	27
Overall	73[‡]	20	51[†]	34	56[‡]	36

Table 5: Results of the human interactive evaluation. Ties are not shown. All the models use BlenderBot as the backbone. ‘w/o ft’ denotes the BlenderBot model without fine-tuning on ESConv. The Joint model outperforms all the competitors on all the metrics (sign test, $\dagger/\ddagger$ denote p -value $< 0.1/0.05$ respectively).

我们比较三对模型：(a) Joint vs. BlenderBot（未在 ESConv 上 fine-tune），(b) Joint vs. Vanilla，(c) Joint vs. Random（使用随机选择策略）。为更好模拟真实策略出现情况，Random 模型按 ESConv 中的策略分布（表 3）随机选择策略。

每对模型通过 100 场与人类参与者的对话进行比较（表 5）。比较 (a) 的结果显示，在 ESConv 上 fine-tune 之后，BlenderBot 提供 ES 的能力在所有指标上都有显著提升。通过比较 (b)，我们发现使用策略可以更好地安慰用户。比较 (c) 的结果也表明，恰当的策略时机对于帮助用户识别问题和提供有效建议至关重要。总体而言，通过在 ESConv 上以策略预测监督进行 fine-tune，预训练模型变得更受用户偏好，这证明了 ESConv 的高质量 and 效用。

6.5 Human Interactive Evaluation 的进一步分析




Figure 5: The Joint model’s generation distribution. The meanings of all the graphics and abbreviations are consistent with Figure 4.

本节探索对话模型从 ESConv 中学到了什么。首先，我们基于 human interactive experiments 中用户与 Joint 模型之间的 300 场对话分析策略分布。如图 5 所示（计算方式与图 4 一致），Joint 模型采用的策略分布与 ESConv 中的真实分布（图 4）非常相似。这提供了重要证据：模型会像人类 supporter 一样模仿策略选择与使用，从而实现更有效的 ES。其次，我们在图 7 中展示一个 case study。案例显示，Joint 模型提供了更具支持性的回应，并在对话中使用了更多技能；而未 fine-tune 的 BlenderBot 似乎不能很好理解用户痛苦，并更倾向于谈论自己。这可能意味着，拥有更多支持性回应以及多样的 support strategies 对有效情感支持至关重要。

7 结论

本文定义了 Emotional Support Conversation 任务，并提出 ESC Framework。该框架从 Helping Skills Theory 调整到对话系统场景中，将情感支持刻画为三个阶段，并给出每个阶段对应的有用 support strategies。随后，我们构建了 Emotional Support Conversation 数据集 ESConv。我们谨慎设计数据收集流程，并设置多种机制以确保对话中 ES 的有效性。最后，我们使用 state-of-the-art 对话模型评估 ES 能力。实验结果显示，ESConv 有潜力提升对话系统提供有效 ES 的能力。本文工作可以促进未来 ES 对话系统研究，同时也能改进其他情感支持发挥重要作用的对话场景中的模型。Strategy selection with realization、user state modeling 以及 task evaluation 是未来研究的重要方向。

致谢

本工作得到 NSFC 项目支持（重点项目 No. 61936010，普通项目 No. 61876096）。本工作也得到清华大学国强研究院支持，资助编号为 2019GQG1 和 2020GQG0005。

伦理考量

人类可能寻求或提供的支持有多种类型和层级，例如专业支持与同伴支持；其中某些层级可能不适合由系统提供，也可能不现实且风险过高。然而，随着对话系统在日常使用中变得更加普遍，一些场景将会出现，至少某种基本层级的支持性表述可能是必要的。在开发 ESC Framework 时，我们谨慎考虑了哪些会

话支持要素可能适用于对话系统，并省略了明显越界的要素。仍需大量额外工作来确定系统提供何种支持层级是合适的，或者人们可以期待系统提供何种支持；但本文工作为开发能够提供合理、适度支持的系统迈出了谨慎而具体的一步。我们构建的语料库也可以提供示例，支持未来工作进一步探查系统能够或应当提供支持的伦理边界。除这些更广泛的伦理考量外，我们也努力以合乎伦理的方式开展本研究，包括透明地向众包工作者说明数据使用和研究意图、按合理小时工资补偿工作者，并获得 Institutional Review Board 的研究批准。

附录 A：ESConv 中的数据示例

这里详细说明图 1 所展示的对话，以展示我们数据集中包含的标注。详细示例见图 6。每场对话的聊天前问卷都标注了问题类别、情绪类别、情绪强度以及 seeker 情境简介。在每场对话语境中，supporter 使用的策略被标注；数据集中也给出了 seeker 对 supporter 每两条回应的反馈分数。需要注意，并非所有对话都有聊天后的情绪强度标签。这是因为一些 seeker 没有完成聊天后问卷，但由于这些对话满足我们的高质量标准，我们仍将其纳入数据集。

criteria.

Pre-chat Survey	
Problem: Academic pressure	
Emotion: Anxiety	
Emotion Intensity: 5	
Situation: My school was closed due to the pandemic.	
Conversation	
Seeker: I feel so frustrated.	
Supporter (Questions): May I ask why you are feeling frustrated?	
Seeker: My school was closed without any prior warning due to the pandemic.	
Supporter (Affirmation and Reassurance): That is really upsetting and stressful. I commend you for having to deal with that!	
Supporter (Self-disclosure): I know I would have been really frustrated if that happened to me.	
System: Do those messages help you feel better?	★★★★★
Seeker: Yeah! I don't even know what is going to happen with our finals now.	
Supporter (Restatement or Paraphrasing): I can see how that would make you frustrated.	
Supporter (Providing Suggestions): Have you thought about talking to your parents or a close friend about this?	
System: Do those messages help you feel better?	★★★★★
...	
Seeker: I really appreciate your assistance today. I feel better and will take some action this week. Thank you!	
Supporter (Others): You're very welcome! Feel free to chat if you need anything else!	
Post-chat Survey	
Emotion Intensity: 2	

Figure 6: Data example from ESConv. **Blue text:** the help-seeker’s pre-chat survey. **Red text:** strategies used by the supporter. **Orange text:** the question that the systems ask help-seeker to evaluate the helpfulness per two utterances from the supporter. Thus the stars de-

附录 B：策略定义

Question: 询问与问题相关的信息，帮助 help-seeker 表达其面临的议题。开放式问题最佳；封闭式问题可用于获取特定信息。

Restatement or Paraphrasing: 对 help-seeker 的陈述进行简单、更简洁的重述，帮助其更清楚地看见自己的处境。

Reflection of Feelings: 清楚表达并描述 help-seeker 的感受。

Self-disclosure: 透露你曾经有过的相似经历或你与 help-seeker 共享的情绪，以表达共情。

Affirmation and Reassurance: 肯定 help-seeker 的优势、动机和能力，并提供保证与鼓励。

Providing Suggestions: 提供关于如何改变的建议，但要谨慎，不要越界地命令他们怎么做。

Information: 向 help-seeker 提供有用信息，例如数据、事实、观点、资源，或回答问题。

Others: 进行礼貌寒暄，并使用不属于上述类别的其他 support strategies。

	Strategy Transition	Proportion
3-Hop	Qu → AR → Qu	19.65 %
	Qu → RP → Qu	14.55 %
	Qu → RP → AR	12.37 %
	AR → Qu → AR	11.96 %
	Ot → Qu → RP	11.64 %
4-Hop	Qu → AR → Qu → AR	7.00 %
	AR → Qu → AR → Qu	5.13 %
	Ot → Qu → RP → Qu	4.20 %
	PS → Ot → PS → Ot	3.85 %
	Qu → RP → AR → Qu	3.85 %

Table 6: Proportions of top-5 strategy transitions in supporter utterances. Abbreviations are consistent with Figure 4.

附录 C：实现细节

所有模型的实现均基于 Transformer library (Wolf et al., 2020)。我们按照 6:2:2 的比例将 ESConv 划分为训练集、验证集和测试集。由于 ESConv 中的对话通常轮次较长，我们将每段对话切成包含 5 条话语的 conversation pieces，其中包含一条 supporter

回应和此前的 4 条话语。训练期间，我们使用 Adam (Kingma and Ba, 2014) optimizer 训练所有模型，learning rate 为 $5e-5$ 。所有模型训练 5 个 epochs，并选择验证集上 perplexity 最低的 checkpoints 用于评估。推理时，我们 mask 掉其他 tokens，并在回应第一个位置采样一个 strategy token。对于 Random variant models，我们根据表 3 报告的 ESConv 策略分布随机采样策略。回应使用 Top-k 和 Top-p sampling 解码，其中 $p = 0.9$ (Holtzman et al., 2019)、 $k = 30$ 、temperature $\tau = 0.7$ ，repetition penalty 为 1.03。

附录 D：Auto-Approval Criteria

为了建立主文 (第 3.4 节) 所示 auto-approval program 的每条标准，我们为每个过滤规则搜索了最合适的阈值。我们招募了三名训练充分的人工标注者，他们也接受了与 supporter 申请者相同的训练程序。随后，我们从数据集中随机采样 100 场对话，并请三名标注者判断这些对话是否有资格作为有效情感支持的对话。接着，我们利用 post-survey 结果和说话者话语长度为过滤规则选择合适阈值。随后，我们将每条自动过滤规则视为一个 rule annotator，并计算该 rule annotator 与每名人工标注者之间的 Cohen's Kappa (Cohen, 1960) 分数。

表 7 中的一致性分数是每个 rule annotator 与三名人工标注者之间 agreement scores 的 Cohen's Kappa 一致性。我们选择了与人工标注者一致性得分第二高的阈值，并将这些阈值用于过滤规则。我们没有使用一致性最高的阈值组合，因为基于这些阈值的规则更严格，会过滤掉许多对话。然而，第二高分仅略低于最高分，因此基于第二高阈值的规则可以以较小可接受代价保留更多合格对话。因此，一场合格对话要求 supporter 必须至少满足所有四个标准中的三个，help-seeker 必须同时满足两个对应标准。最终的“rule”annotator 结合这两个条件；其与三名人工标注者之间的平均一致性分数为 0.576，表明显著一致。

Auto-approval Rule						Consistency			
Supporter				Seeker		Human1	Human2	Human3	Average
Improvement	Avg. Length	Empathy	Relevance	Detail	Avg. Length				
1	8	3	4	-	6	0.545	0.659	0.525	0.576
2	8	3	4	-	6	0.505	0.566	0.486	0.519
1	8	4	4	-	6	0.539	0.602	0.519	0.553
1	8	2	4	-	6	0.539	0.618	0.570	0.576
1	8	3	3	-	6	0.546	0.630	0.526	0.567
1	8	3	5	-	6	0.575	0.640	0.555	0.590
1	8	3	4	-	7	0.539	0.602	0.473	0.538
1	8	3	4	-	5	0.520	0.551	0.501	0.524
1	8	3	4	3	6	0.505	0.653	0.531	0.563
1	8	3	4	2	6	0.527	0.640	0.508	0.558
1	8	3	4	4	6	0.457	0.599	0.482	0.513
1	9	3	4	-	6	0.510	0.621	0.490	0.540
1	7	3	4	-	6	0.515	0.633	0.495	0.548

Table 7: The agreement score between each “rule” annotator and three human annotators. The aspects are consistent with Table 1. The first rule means: 1) The supporter improves the help-seeker’s emotional state as least one score (emotional improvement is calculated as the help-seeker’s emotion intensity before the conversation minus the emotion intensity after the conversation). 2) The average length of the supporter’s utterances is no less than eight. 3) The empathy score of the supporter’s performance is no less than three. 4) The topic relevance score of the supporter’s performance is no less than four. 5) The score that measures how well the help-seeker goes into detail about their problems is not required to be used in the rule (denoted as ‘-’). (6) The average length of the help-seeker’s utterances is no less than six.

Emotion Intensity: 5 Situation: My friend is drinking too much.	
Joint	BlenderBot w/o Fine-tuning
Seeker: Hi there. I feel sadness because my friend has a drinking problem. Supporter (Question): I am sorry to hear that. What do you think is going on? Seeker: I think he just got used to drink every day and I can't pursue him to stop at least for a week. Supporter (Question): I can see how that would be difficult for you. Does your friend drink at home or does it happen at work or home? Seeker: Well he is working from home. So he is drinking almost 24/7. I feel so exhausted as well. Supporter (Reflection of Feelings): I understand that you feel like you are exhausted, but I think you can get through this! Seeker: I just need a way to make him stop drinking. Maybe I should stop any communication with him for a while? Supporter (Affirmation and Reassurance): I think it's a great idea! I would do it if I were you! Seeker: Probably that's what I will do. I just can't take this anymore. If he wants he can buy drinks himself as I am tired walking to shop every day and all neighbors thinking that I am an alcoholic. Supporter (Self-disclosure): I completely understand where you are coming from. I was in the same situation as you. Seeker: It was so nice to chat with you, I feel better now. Supporter (Affirmation and Reassurance): You're welcome! I'm glad I could help!	Seeker: Hi there. My friend has a drinking problem and I don't know what to do. Supporter: I know it can be difficult, but if you can do it, I'm sure you can find a way. I hope he gets better soon. Seeker: I feel such a sadness inside me. I am trying to help him but he won't listen. Supporter: I understand completely. it is tough, but I am sure you will get through it. Seeker: Every day he is drinking beer and he is not listening to me. Supporter: I can imagine. I feel like that's the only way I can keep up with him. I have tried so hard. I think I just have to try harder than him to get through this. Seeker: Few more months and I think I will give up on him Supporter: That is exactly how I feel... I am trying to find the right person for me and I can't do it! Seeker: I thought you are here to help me? Supporter: It's hard, but we all have to stick together. There are so many people out there, you just have time. Seeker: Maybe I should ignore my friend for a while? Maybe I will feel better? Supporter: I try to just hang out with friends. I have been trying to meet new people in the city but they just don't show up. I just want to be alone and be alone. Seeker: Thank you for your help. Supporter: You're welcome. I think that's what I'll do too. I'm trying to get used to the city life. I feel like I've been stuck in this city for so long.

Figure 7: Case Study. **Blue text:** the help-seeker’s pre-chat survey. **Red text:** strategies predicted by the model. **Green background:** utterances that corresponding to the used strategies. **Yellow background:** utterances where the model talks about itself and is not user-centered.

附录 E：数据收集平台界面

为了帮助读者直观理解我们的数据收集过程，我们在图 8 中展示了数据收集过程中一些重要步骤的界面示

意图，包括 support strategy training、supporter 聊天、help-seeker 聊天前问卷、help-seeker 聊天以及 post-survey。




Figure 8: (a) Support strategy training. (b) Pre-chat survey. (c) The help-seeker's chatting interface. (d) The supporter's chatting interface. (e) Post-chat survey.

References（保留原文）

- Amit Baume, 2015. Online emotional support delivered by trained volunteers: users' satisfaction and their perception of the service compared to psychotherapy. *Journal of Mental Health*, 24(5):313-320.
- Brant R Burleson. 2003. Emotional support skill. *HANDBOOK OF COMMUNICATION AND SOCIAL INTERACTION SKILLS*, page 551.
- Jacob Cohen. 1960. A coefficient of agreement for nominal scales. *Educational and psychological measurement*, 20(1):37-46.
- Catherine A Heaney and Barbara A Israel. 2008. Social networks and social support. *Health behavior and health education: Theory, research, and practice*, 4:189-210.
- Clara E Hill. 2009. Helping skills: Facilitating, exploration, insight, and action. *American Psychological Association*.
- Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, and Yejin Choi. 2019. The curious case of neural text degeneration.

In International Conference on Learning Representations.

Mahshid Hosseini and Cornelia Caragea. 2021. It takes two to empathize: One to seek and one to provide. *Proceedings of the 35th American Association for Artificial Intelligence (AAAI 2021)*.

Minlie Huang, Xiaoyan Zhu, and Jianfeng Gao. 2020. Challenges in building intelligent open-domain dialog systems. *ACM Transactions on Information Systems (TOIS)*, 38(3):1-32.

Bernd Huber, Daniel McDuff, Chris Brockett, Michel Galley, and Bill Dolan. 2018. Emotional dialogue generation using image-grounded language models. In *Proceedings of the 2018 CHI Conference on Human Factors in Computing Systems*, pages 1-12.

Diederik P Kingma and Jimmy Ba. 2014. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.

Catherine Penny Hinson Langford, Juanita Bowsher, Joseph P Maloney, and Patricia P Lillis. 1997. Social

- support: a conceptual analysis. *Journal of advanced nursing*, 25(1):95-100.
- Yanran Li, Hui Su, Xiaoyu Shen, Wenjie Li, Ziqiang Cao, and Shuzi Niu. 2017. DailyDialog: A manually labelled multi-turn dialogue dataset. In *Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 986-995, Taipei, Taiwan.
- Chin-Yew Lin. 2004. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74-81, Barcelona, Spain.
- Zhaojiang Lin, Andrea Madotto, Jamin Shin, Peng Xu, and Pascale Fung. 2019. MoEL: Mixture of empathetic listeners. In *Proceedings of EMNLP-IJCNLP*, pages 121-132, Hong Kong, China.
- Chia-Wei Liu, Ryan Lowe, Iulian Serban, Mike Noseworthy, Laurent Charlin, and Joelle Pineau. 2016. How NOT to evaluate your dialogue system: An empirical study of unsupervised evaluation metrics for dialogue response generation. In *Proceedings of EMNLP*, pages 2122-2132.
- Edward Loper and Steven Bird. 2002. Nltk: the natural language toolkit. *arXiv preprint cs/0205028*.
- Navonil Majumder, Pengfei Hong, Shanshan Peng, Jiankun Lu, Deepanway Ghosal, Alexander Gelbukh, Rada Mihalcea, and Soujanya Poria. 2020. MIME: MIMicking emotions for empathetic response generation. In *Proceedings of EMNLP*, pages 8968-8979.
- Lenin Medeiros and Tibor Bosse. 2018. Using crowdsourcing for the development of online emotional support agents. In *International Conference on Practical Applications of Agents and Multi-Agent Systems*, pages 196-209. Springer.
- Burt L Monroe, Michael P Colaresi, and Kevin M Quinn. 2008. Fightin' words: Lexical feature selection and evaluation for identifying the content of political conflict. *Political Analysis*, 16(4):372-403.
- Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. Bleu: a method for automatic evaluation of machine translation. In *Proceedings of ACL*, pages 311-318.
- Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. 2019. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9.
- Stephen A Rains, Corey A Pavlich, Bethany Lutovsky, Eric Tsseti, and Anjali Ashtaputre. 2020. Support seeker expectations, support message quality, and supportive interaction processes and outcomes: The case of the comforting computer program revisited. *Journal of Social and Personal Relationships*, 37(2):647-666.
- Hannah Rashkin, Eric Michael Smith, Margaret Li, and Y-Lan Boureau. 2019. Towards empathetic open-domain conversation models: A new benchmark and dataset. In *Proceedings of ACL*, pages 5370-5381.
- Stephen Roller, Emily Dinan, Naman Goyal, Da Ju, Mary Williamson, Yinhan Liu, Jing Xu, Myle Ott, Kurt Shuster, Eric M Smith, et al. 2020. Recipes for building an open-domain chatbot. *arXiv preprint arXiv:2004.13637*.
- Ashish Sharma, Adam Miner, David Atkins, and Tim Althoff. 2020a. A computational approach to understanding empathy expressed in text-based mental health support. In *Proceedings of EMNLP*, pages 5263-5276.
- Ashish Sharma, Adam S Miner, David C Atkins, and Tim Althoff. 2020b. A computational approach to understanding empathy expressed in text-based mental health support. *arXiv preprint arXiv:2009.08441*.
- Shikhar Sharma, Layla El Asri, Hannes Schulz, and Jeremie Zumer. 2017. Relevance of unsupervised metrics in task-oriented dialogue for evaluating natural language generation. *arXiv preprint arXiv:1706.09799*.
- Siqi Shen, Charles Welch, Rada Mihalcea, and Verónica Pérez-Rosas. 2020. Counseling-style reflection generation using generative pretrained transformers with augmented context. In *Proceedings of SIGDIAL*, pages 10-20.
- Hao Sun, Zhenru Lin, Chujie Zheng, Siyang Liu, and Minlie Huang. 2021. Psyqa: A chinese dataset for generating long counseling text for mental health support. In *Findings of ACL 2021*.
- Janneke M van der Zwaan, Virginia Dignum, and Catholijn M Jonker. 2012. A conversation model enabling intelligent agents to give emotional support. In *Modern Advances in Intelligent Systems and Tools*, pages 47-52. Springer.
- JM Van der Zwaan, V Dignum, and CM Jonker. 2012. A bdi dialogue agent for social support: Specification and evaluation method. In *AAMAS 2012, Workshop on Emotional and Empathic Agents*.
- Charles Welch, Allison Lahnlala, Veronica Perez-Rosas, Siqi Shen, Sarah Seraj, Larry An, Kenneth Resnicow, James Pennebaker, and Rada Mihalcea. 2020. Expressive interviewing: A conversational system for coping with COVID-19. In *Proceedings of the 1st Workshop on NLP for COVID-19 (Part 2) at EMNLP 2020*.
- Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Remi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, and Alexander Rush. 2020. Transformers: State-of-the-art natural language processing. In *Proceedings of EMNLP: System Demonstrations*, pages 38-45.
- Rohola Zandie and Mohammad H Mahoor. 2020. Emptransfo: A multi-head transformer architecture for creating empathetic dialog systems. *arXiv preprint arXiv:2003.02958*.
- Yizhe Zhang, Siqi Sun, Michel Galley, Yen-Chun Chen, Chris Brockett, Xiang Gao, Jianfeng Gao, Jingjing Liu, and Bill Dolan. 2020. DIALOGPT: Large-scale generative pre-training for conversational response generation. In *Proceedings of ACL: System Demonstrations*, pages 270-278.
- Chujie Zheng, Yong Liu, Wei Chen, Yongcai Leng, and Minlie Huang. 2021. Comae: A multi-factor hierarchical framework for empathetic response generation. In *Findings of ACL 2021*.
- Peixiang Zhong, Chen Zhang, Hao Wang, Yong Liu, and Chunyan Miao. 2020. Towards persona-based empathetic conversational models. In *Proceedings of EMNLP*, pages 6556-6566.
- Hao Zhou, Minlie Huang, Tianyang Zhang, Xiaoyan Zhu, and Bing Liu. 2018. Emotional chatting machine: Emotional conversation generation with internal and external memory. In *Proceedings of AAAI*.
- Li Zhou, Jianfeng Gao, Di Li, and Heung-Yeung Shum. 2020. The design and implementation of xiaoice, an empathetic social chatbot. *Computational Linguistics*, 46(1):53-93.
- Xianda Zhou and William Yang Wang. 2018. MojiTalk: Generating emotional responses at scale. In *Proceedings of ACL*, pages 1128-1137.