

面向情绪支持对话系统

Siyang Liu^{1,2*}, Chujie Zheng^{1*}, Orianna Demasi³, Sahand Sabour¹, Yu Li³, Zhou Yu⁴, Yong Jiang², Minlie Huang^{1†}

¹The CoAI group, DCST, Institute for Artificial Intelligence, State Key Lab of Intelligent Technology and Systems, Beijing National Research Center for Information Science and Technology, Tsinghua University, Beijing 100084, China

²Tsinghua-Berkeley Shenzhen Institute, Tsinghua Shenzhen International Graduate School, Tsinghua University, Shenzhen, China

³University of California, Davis ⁴Columbia University

siyang-l18@mails.tsinghua.edu.cn, chujiezhengchn@gmail.com, aihuang@tsinghua.edu.cn

* 同等贡献。† 通讯作者。数据和代码见: <https://github.com/thu-coai/Emotional-Support-Conversation>

摘要

情绪支持 (Emotional Support, ES) 是许多对话场景中的关键能力, 包括社交互动、心理健康支持以及客户服务聊天。遵循合理流程并使用多种支持技能, 有助于有效地提供支持。然而, 由于缺少设计完善的任务以及能够体现有效情绪支持对话的语料, 在对话系统中构建情绪支持能力的研究仍基本空白。本文定义了情绪支持对话 (Emotional Support Conversation, ESC) 任务, 并提出了一个基于 Helping Skills Theory (Hill, 2009) 的 ESC Framework。我们构建了一个情绪支持对话数据集 ESConv, 并在求助者与支持者模式下加入了丰富标注, 尤其是支持策略标注。为了确保语料包含能够提供有效情绪支持的高质量对话示例, 我们投入了大量工作, 为支持者设计训练教程, 并在数据收集过程中设置了若干质量控制机制。最后, 我们评估了 state-of-the-art 对话模型提供情绪支持的能力。结果表明, 支持策略对于提供有效情绪支持具有重要作用, ESConv 也有助于训练更具情绪支持能力的系统。




Figure 1: An example chat showing effective emotional support (adapted from ESConv) being provided to the help-seeker(left) by the supporter(right). The **support strategies (skills)** used by the supporter are marked in the parentheses before the utterances. The **red bold texts** in the dashed boxes highlight the three stages of our proposed ESC Framework (Figure 3).

1 引言

情绪支持旨在降低个体的情绪痛苦，并帮助他们理解和处理正在面临的挑战（Burleson, 2003; Langford et al., 1997; Heaney and Israel, 2008）。对于需要日常与用户互动的对话系统而言，情绪支持是一项关键能力（Van der Zwaan et al., 2012; Zhou et al., 2020），尤其适用于社交互动（陪伴和鼓励用户）、心理健康支持（安慰受挫的求助者并帮助识别问题）、客户服务聊天（安抚愤怒客户并提供解决方案）等场景。近期研究也表明，人们更偏好能够给出更具支持性的回复的对话系统（Rains et al., 2020）。

研究显示，提供情绪支持并不是一种完全凭直觉就能掌握的能力（Burleson, 2003），因此已有研究提出了相应流程和会话技能（Hill, 2009），以帮助人们通过对话提供更好的支持。图1展示了我们收集到的一段对话，其中可以看到这些技能的使用。为了识别求助者痛苦的原因，支持者首先探索求助者的问题。若缺少探索，支持者很可能无法理解求助者的经历和感受；此时如果给出无关建议，例如“你可以出去散步放松一下”，就可能显得冒犯，甚至造成伤害。在了解求助者处境的过程中，支持者可以运用多种技能表达理解与共情，以缓解求助者的挫败感，例如 Self-disclosure、Reflection of Feelings 等。在理解求助者的问题之后，支持者可以提供建议，帮助求助者应对问题。如果支持者只是安慰求助者，却没有启发其采取行动并促成改变，那么就未必能有效改善求助者的情绪。最后，在这段示例对话的数据收集过程中，求助者报告其情绪强度从 5 降至 2（情绪强度是本文语料中的标注项；附录A给出了该对话示例的详细标注），这表明支持者提供的 ES 具有有效性。

尽管 ES 十分重要且复杂，但由于缺少任务设计以及相关语料，面向数据驱动的 ES 对话系统研究仍然有限；尤其缺少能够展示多样 ES 技能使用方式的对话语料。首先，现有与情绪聊天（Zhou et al., 2018）或共情回复（Rashkin et al., 2019）相关的研究系统，通常只能返回表达情绪或共情的消息，因此功能有限，因为它们无法覆盖许多在有效 ES 中常用的其他技能（Hill, 2009）。图2说明了三类任务之间的关系，2.1节将进一步讨论。其次，人们并非天生就善于提供支持，因此已有指南被用于训练人类如何更具支持性。没有经过训练的个体时，现有在线对话数据集（Sharma et al., 2020a; Rashkin et al., 2019; Zhong et al., 2020; Sun et al., 2021）通常不会自然呈现支持性对话的示例或要素。因此，利用这些语料的数据驱动模型（Radford et al., 2019; Zhang et al., 2020; Roller et al., 2020）在显式学习如何使用支持技能、进而提供有效 ES 方面受到限制。




Figure 2: Emotional support conversations (our can include elements of emotional chatting (Zhou 2018) and empathetic responding(Rashkin et al., 2

本文定义了 Emotional Support Conversation (ESC) 任务，其目标是通过社交互动（如同伴、朋友或家人之间的互动）而非专业咨询来提供支持，并提出了一个基于 Helping Skills Theory (Hill, 2009) 且为对话系统设置进行调整的 ESC Framework (图3)。我们通过改造 Hill 的会话支持模型中相关组成部分，谨慎地设计出适合对话系统场景的 ESC Framework。该框架提出三个阶段（Exploration、Comforting 和 Action），每个阶段包含若干支持策略（或技能）。为了促进情绪支持对话研究，我们随后构建了情绪支持对话数据集 ESConv，并投入多方面工作，以确保对话具有丰富标注，且所有对话都能作为这一复杂对话任务的高质量样例。ESConv 由众包工作者分别扮演求助者和支持者进行对话而收集。

我们基于 ESC Framework 设计教程并训练所有支持者，同时设计了多种人工与自动机制，以确保对话中情绪支持的有效性。最后，我们评估了 state-of-the-art 模型，并观察到在使用多种支持策略时，模型提供的情绪支持显著改善。对交互式评估结果的进一步分析表明，Joint 模型能够模拟人类支持者在策略使用方面的行为。我们相信，本文工作将推动更多数据驱动方法研究，帮助构建能够提供有效情绪支持的对话系统。

2 相关工作

2.1 情绪对话与共情对话

图2直观展示了 ESC、情绪对话和共情对话之间的关系。已有研究表明，情绪对于构建更具吸引力的对话系统非常重要 (Zhou et al., 2018; Li et al., 2017; Zhou and Wang, 2018; Huber et al., 2018; Huang et al., 2020)。作为情绪对话领域的代表性工作，Zhou et al. (2018) 提出了 Emotional Chatting Machine (ECM)，在给定预设情绪的情况下生成带有情绪的回复。该任务要求在生成回复中准确表达（指定或非指定的）情绪。ES 或许会包含表达情绪，例如快乐或悲伤，但它具有更广泛的目标：通过使用恰当的支持技能降低用户的情绪痛苦。这一点与情绪聊天有根本差异。情绪聊天只是对话系统的一项基本质量，而 ES 是对话系统有望具备的更高层次、更复杂的能力。另一项相关任务是共情回复 (Rashkin et al., 2019; Lin et al., 2019; Majumder et al., 2020; Zandie and Mahoor, 2020; Sharma et al., 2020a; Zhong et al., 2020; Zheng et al., 2021)，其目标是理解用户感受并据此回应。例如，Rashkin et al. (2019) 认为，对话模型可以通过识别对话对象的感受来生成更具共情性的回复。有效的 ES 自然要求根据求助者的经历和感受表达共情，这一点也体现在我们提出的 Emotional Support Framework 中 (3.2 节，图3)。因此，共情回复只是情绪支持的必要组成部分之一。除共情回复外，情绪支持对话还需要探索用户的问题，并帮助他们应对困难。

2.2 与情绪支持相关的数据集

许多工作在社交语境下考虑了情绪支持对话，例如社交媒体或在线论坛中的对话 (Medeiros and Bosse, 2018; Sharma et al., 2020b; Hosseini and Caragea, 2021)。Medeiros and Bosse (2018) 从 Twitter 收集了与压力相关的帖子和回复对，并将回复划分为支持性类别。Sharma et al. (2020b) 对来自 TalkLife 和心理健康 subreddit 的帖子-回复对进行了标注，标注内容为文本共情表达的沟通机制（其中只有 Reddit 部分的数据公开可用）。Hosseini and Caragea (2021) 也从在线支持小组收集了此类帖子-回复对，并将其标注为需要支持或表达支持。这些语料中的对话要么是单轮互动（帖子-回复对），要么是非常短的对话，这限制了其有效 ES 的潜力，因为 ES 通常需要多轮互动 (Hill, 2009)。

2.3 情绪支持对话系统

一些传统对话系统采用人工编写规则来提供情绪支持回复 (Van der Zwaan et al., 2012; van der Zwaan et al., 2012)。近期一个系统考虑了基于规则的算法，用于确定回复中使用的支持行为，然后从预定义候选列表中选择恰当回复 (Medeiros and Bosse, 2018)。另一个旨在为应对 COVID-19 提供支持的会话系统，则通过识别用户提到的话题，然后使用模板生成反映性回应，或从预定义词典中选择消息进行回复 (Welch et al., 2020)。很少有研究专注于生成支持性回复；即便已有相关研究，其范围也较为有限。例如，Shen et al. (2020) 探索了如何通过反映用户输入来生成支持性回复。

3 情绪支持对话

3.1 任务定义

当用户由于某个具体问题而处于不佳情绪状态时，他们可能会寻求帮助以改善情绪状态。在这种设定下，可以为用户标注一个负面情绪标签 e 、一个情绪强度等级 l （例如范围为 1 到 5），以及用户正在经历的潜在挑战。支持者（或系统）需要在对话中运用支持技能安慰用户，并降低其情绪强度等级。需要注意的是，在对话之前，支持者并不知道用户的状态。在对话过程中，支持者需要识别用户正在面对的问题，安慰用户，然后提供一些建议或信息，帮助用户采取行动来应对问题。如果对话结束时用户的情绪强度等级降低，或者更具体地说，如果支持者能够有效识别问题、安慰用户并提供解决方案或建议，那么这段情绪支持对话就是有效的。

ESC 任务包含若干子问题：（1）支持策略选择与策略约束的回复生成。后文实验（6.4节）显示，策略应用的时机与 ES 有效性相关。因此，生成回复符合特定策略十分重要。（2）情绪状态建模。动态建模和追踪用户情绪状态非常重要，既有助于动态策略选择，也有助于衡量 ESC 的有效性。（3）支持有效性的评估。除了传统上评价对话相关性、连贯性和用户参与度的维度外，ESC 还提出了评估 ES 有效性这一新维度。

3.2 ESC Framework

我们提出了一个 ESC Framework，将情绪支持流程划分为三个阶段，每个阶段配有若干建议支持策略。该框架基于 Hill 的 Helping Skills Theory (Hill, 2009)，并将其调整为更适合对话系统的设置，目标是通过社交互动（如同伴、朋友或家人之间的互动）而不是单纯专业咨询来提供支持。ESC Framework 的会话阶段与策略概览见图3。

阶段。Hill (2009) 提出了支持他人的三个阶段：exploration（探索，帮助求助者识别问题）、insight（洞察，帮助求助者进入更深层次的自我理解）和 action（行动，帮助求助者决定采取什么行动以应对问题）。不过，我们注意到 insight 通常要求重新解释用户的行为和感受。对于缺乏充分支持经验的支持者来说，这既困难又有风险。因此，我们将 insight 调整为 comforting（安慰），定义为通过共情和理解提供支持。虽然情绪支持对话建议以这三个有序阶段为目标，但在实践中，对话无法遵循固定或线性的顺序，必须进行适当调整。如 Hill (2009) 所建议，这三个阶段可以灵活调整，以满足求助者的需要。

策略。Hill (2009) 也为每个阶段提供了若干推荐会话技能。某些技能在缺乏专业监督和经验的对话系统场景中并不适合。为将这些技能调整到适合对话系统的场景，我们从中抽取了七种方法，并另设“Others”类别。在本文任务以及下文中，我们称这些方法为策略。附录B给出了每种策略的详细定义。例如，名为 challenging 的技能是指出求助者未意识到或不愿改变的矛盾或非理性信念，这通常需要专业经验，对普通人来说过于困难。




Figure 3: Overview of our proposed ESC Framework. It contains three stages and suggested support strategies. The procedure of emotional support generally follows the order: ①Exploration → ②Comforting → ③Action (as indicated by the **black** arrows), but it can also be adapted to the individual conversation as needed (indicated by the **dashed gray** arrows). The column of “Lexical Features” displays top 5 unigrams or bigrams associated with messages that use each strategy in our dataset. Each feature is ranked by the rounded z -scored log odds ratios (Monroe et al., 2008) in the parentheses.

4 数据收集

为了促进对话系统中情绪支持技能的研究，我们引入了情绪支持对话数据集 ESConv。该数据集通过众包工作者分别扮演求助者和支持者的模式收集。由于这一复杂任务需要高质量的对话示例，我们付出了大量努力来尽可能确保对话中 ES 的有效性。这些工作主要包括：（1）由于提供会话支持是一种必须经过训练才能有效掌握的技能 (Burlinson, 2003)，我们基于 ESC Framework 设计教程并训练众包工作者成为支持者，只有通过考核者才能参与任务。（2）我们要求求助者在聊天前完成关于其问题和情绪的预聊天问卷，并在对话过程中和对话后提供反馈。（3）我们设计并使用多种人工或自动机制，在收集原始对话数据后过滤低质量对话。

4.1 面向支持者的任务

训练与考核。为了教会众包工作者如何提供有效情绪支持，我们基于 ESC Framework 设计了教程。受 7cups (7cups.com) (Baumel, 2015) 的启发，我们设计了 11 个子任务 (3 + 8)，帮助工作者学习三个阶段和八种支持策略的定义。每个子任务都包含一段示例对话片段及相应测验问题。如3.2节所述，我们也告知参与者，对话不一定能遵循固定顺序，他们可能需要灵活调整阶段转换。

策略标注。为了鼓励支持者在对话中使用 ESC 支持策略，并使得到的数据集更具结构化，我们要求支持者先根据对话上下文选择一个他们想要使用的恰当策略，然后再写出体现该策略的话语。如果支持者想使用多种策略来提供支持，我们鼓励他们发送多条消息。

聊天后问卷。每段对话结束后，支持者需要用五点 Likert 量表评价求助者对其问题描述的详细程度。

4.2 面向求助者的任务

聊天前问卷。每段对话前，求助者需要完成以下问卷：（1）问题与情绪类别：求助者应从 5 个选项中选择一个问题类别，并从 7 个选项中选择一种情绪类别（这些选项基于试点数据集中的对话而设定）。（2）情绪强度：从 1 到 5 的分数（数字越大，情绪越强烈）。（3）情境：开放文本，用于描述造成情绪问题的原因。（4）经历来源：所描述情境是求助者当前经历，还是基于过往生活情境。我们发现，75.2% 的对话来源于求助者当前经历。

反馈。在对话过程中，求助者每收到支持者的两条新话语后，需要给出反馈。他们用 5 星量表对支持者消息的有用性评分。我们将每段对话划分为三个阶段，并计算每个阶段的平均反馈分数。三个阶段的分数分别为 4.03、4.30 和 4.44，表明支持者接受了充分训练，能够有效帮助求助者感觉更好。

聊天后问卷。每段对话结束后，求助者需要用五点 Likert 量表评价其情绪以及支持者表现：（1）情绪支持对话后的情绪强度（相较于对话前强度的下降反映情绪改善），（2）支持者对求助者经历和感受的共情与理解程度，以及（3）支持者回复与对话主题的相关性。

4.3 质量控制

我们使用多种方法确保语料包含有效情绪支持对话的高质量示例。

初步过滤机制。在招募支持者角色参与者时，我们最初收到 5,449 名申请者，但只有 425 人 (7.8%) 通过训练教程。在最初收集的 2,472 段对话中，我们过滤掉了未由求助者完成的对话，以及话语数少于 16 的对话。该过滤保留了 1,342 段对话 (54.3%) 进入后续考虑。

合格对话的自动通过程序。我们精心设计了自动通过程序，这是数据质量控制中最重要的部分。该程序根据两个角色的聊天后问卷回答以及话语长度设置标准，具体见表1。这些标准基于初始人工审查结果。附录 D 说明了如何选择这些自动通过标准。计算得到的对话前平均情绪强度为 4.04，对话后为 2.14。这种改善显示了支持者所提供情绪支持的有效性。在少数对话中，求助者没有完成聊天后问卷，因此我们为这些对话添加了另一项标准：求助者最后两次反馈分数都必须大于 4。因此，在所有没有聊天后问卷的对话中，只有同时满足（2）和（3）的对话才合格。利用这些质量标准，共有 1,053 段对话 (1,342 段中的 78.5%) 被判为合格。

标注修正。为了进一步确保数据质量，我们审查并修正了支持策略和求助者情绪强度的错误标注。（1）对于策略标注修正，我们邀请新的合格支持者在必要时审查并修订此前收集对话中的标注，共有 2,545 条话语 (17.1%) 被审查。对于超过 75% 审查者不同意的标注，我们进行人工复核，并修订了其中 139 条。

（2）根据自动通过标准（表7），当求助者情绪改善得分小于 1，但其他三个标准满足时，对话也可能合格。复核后，我们发现这通常源于求助者将负面情绪强度误解为情绪正向程度。我们利用其他有用信息，例如聊天后问卷开放题回答和聊天过程中的求助者反馈分数，对这些对话的情绪强度进行了人工复核和修正。在 130 段此类对话中，92% 被修订并纳入语料。

Roles	Aspects	Criteria
Supporter (≥ 3)*	Understanding the help-seeker's experiences and feelings (<i>rated by the help-seeker</i>)	≥ 3
	Relevance of the utterances to the conversation topic (<i>rated by the help-seeker</i>)	≥ 4
	Average length of utterances	≥ 8
	Improvement in the help-seeker's emotion intensity (<i>rated by the help-seeker</i>)**	≥ 1
Seeker	Describing details about the own emotional problems (<i>rated by the supporter</i>)	not required
	Average length of utterances	≥ 6

Table 1: Criteria of high-quality conversations. * denotes that supporters must meet at least two of the three criteria. In **, the improvement of the help-seeker's emotion intensity was calculated by subtracting the in

5 数据特征

5.1 统计信息

1,053 个 ESConv 示例的总体统计见表2。相对较长的对话（平均 29.8 条话语）说明，提供有效 ES 通常需要多轮互动；这一轮数也明显多于此前情绪聊天（Zhou et al., 2018）或共情对话（Rashkin et al., 2019）数据集中的典型轮数。其他标注的统计见表3。或许由于当前 COVID-19 疫情的影响，持续性抑郁和工作危机是求助者最常陈述的问题，抑郁和焦虑则是最常见的情绪。从求助者反馈来看，他们通常对情绪支持高度满意，这进一步表明基于 ESC Framework 的训练教程确实帮助支持者学会提供有效 ES。我们公开所有这些标注，以促进后续研究。

Category	Total	Supporter	Seeker
# dialogues	1,053	-	-
Avg. Minutes per Chat	22.6	-	-
# Workers	854	425	532
# Utterances	31,410	14,855	16,555
Avg. length of dialogues	29.8	14.1	15.7
Avg. length of utterances	17.8	20.2	15.7

Table 2: Statistics of ESConv.

	Categories	Num	Proportion
Seeker's Problem	Ongoing Depression	306	29.1%
	Job Crisis	233	22.1%
	Breakup with Partner	216	20.5%
	Problems with Friends	159	15.1%
	Academic Pressure	139	13.2%
	Overall	1,053	100.0%
Seeker's Emotion	Anxiety	281	26.7%
	Depression	276	26.2%
	Sadness	250	23.7%
	Anger	96	9.1%
	Fear	88	8.4%
	Disgust	32	3.0%
	Shame	30	2.8%
	Overall	1,053	100.0%
Seeker's Feedback	1 (Very Bad)	71	1.1%
	2 (Bad)	183	2.9%
	3 (Average)	960	15.5%
	4 (Good)	1,855	29.9%
	5 (Excellent)	3,144	50.6%
	Overall	6,213	100.0%
Support Strategy	Question	3,109	20.9%
	Restatement or Paraphrasing	883	5.9%
	Reflection of Feelings	1,156	7.8%
	Self-disclosure	1,396	9.4%
	Affirmation and Reassurance	2,388	16.1%
	Providing Suggestions	2,323	15.6%
	Information	904	6.1%
	Others	2,696	18.1%
	Overall	14,855	100.0%

Table 3: Statistics of all the annotations, including the help-seekers' problems, emotions, feedback, and the support strategies.

5.2 策略分析




Figure 4: The distribution of strategies at different conversation progress.

词汇特征。我们为每种策略提取词汇特征，方法是计算各策略相对于其他所有策略中所有 unigram 和 bigram 的 log odds ratio，并使用 informative Dirichlet prior (Monroe et al., 2008)。每种策略的前5个短语列在图3中。所有策略都与某些短语显著相关 (z-score > 3)，例如 Question 与 “are you” 相关，Self-disclosure 与 “me” 相关。

策略分布。我们计算了对话不同阶段的策略分布。设某段对话共有 L 条话语，第 k 条 ($1 \leq k \leq L$) 话语来自支持者并采用策略 st ，则我们称其位于对话进度 k/L 。具体而言，我们将对话进度划分为六个区间： $[0,1] = \bigcup_{i=0}^4 [i/5, (i+1)/5) \cup \{1\}$ 。随后，对于 ESConv 中的所有对话，我们统计了六个区间内不同策略的比例，并在六个点 $i/5$ ($i = 0, \dots, 5$) 上绘制这些分布并连接起来，最终得到图4。

总体而言，支持者遵循 ESC Framework (图3) 建议的阶段顺序，但也会灵活调整阶段和策略。例如，在对话早期，支持者通常采用探索性策略，如 Question。在了解求助者处境后，支持者倾向于提供自己的看法，例如 Providing Suggestions。在整个对话中，安慰性策略（如 Affirmation and Reassurance）都会被使用，并在消息中保持相对稳定的比例。

策略转换。我们在附录（表6）中展示了最常见的前5个 3-hop / 4-hop 策略转换。这些转换表明，正如 ESC Framework 教程所训练的那样，支持者通常会先提问并探索求助者的处境，然后再安慰求助者。

6 实验

我们的实验聚焦两个关键问题：（1）带有策略标注的 ESConv 能在多大程度上改进 state-of-the-art 生成式对话模型？（2）这些模型能否从 ESConv 中学习提供有效的情绪支持？

6.1 骨干模型

我们使用两个 state-of-the-art 预训练模型作为被比较变体模型的 backbone：

BlenderBot。BlenderBot (Roller et al., 2020) 是一个开放域会话智能体，使用多种沟通技能进行训练，其中包括共情回复。因此，BlenderBot 应在一定程度上具备为用户提供 ES 的能力。实验中我们使用 BlenderBot 的 small 版本，因为较大版本的最大上下文长度限制为 128；我们发现这一限制会损害模型性能和回复连贯性。

DialoGPT。我们还评估了 DialoGPT (Zhang et al., 2020)，这是一个基于 GPT-2 的模型，在大规模对话语料上进行预训练。我们使用 small 版本。

6.2 变体模型

以上述每个预训练模型为 backbone，我们构建了以下变体模型：

Vanilla。直接在 ESConv 上微调 backbone 模型，不接入策略标注。形式化地，设展平后的对话历史为 x ，将要生成的回复为 y ，则最大化条件概率： $P(y|x)=\prod_{i=1}^{|y|}P(y_i|x,y_{<i})$ 。

带策略的变体。为了将策略标注纳入 backbone 模型，我们使用特殊 token 表示每种策略。对于支持者的一条话语 y ，我们在其前面附加对应的策略 token： $\tilde{y} = [st] \oplus y$ ，其中 $[st]$ 表示所用策略的特殊 token。随后，将展平的对话历史 x 作为输入，模型生成以第一个预测（或指定）的策略 token 为条件的回复： $P(\tilde{y}|x)=P([st]|x)\prod_{i=1}^{|y|}P(y_i|x,[st],y_{<i})$ 。

在后续实验中，我们研究了三个使用策略标注的变体：（1）Oracle：在 gold reference 策略 token 条件下生成回复。（2）Joint：在预测（采样）策略 token 条件下生成回复。（3）Random：在随机选择的策略条件下生成回复。实现细节见附录C。

6.3 自动评估

为了研究在以 BlenderBot 或 DialoGPT 为 backbone 时，使用支持策略对模型性能的影响，我们比较了上述 Vanilla、Joint 和 Oracle 变体的表现。采用的自动指标包括 perplexity (PPL)、BLEU-2 (B-2) (Papineni et al., 2002)、ROUGE-L (R-L) (Lin, 2004) 以及基于 BOW Embedding 的 (Liu et al., 2016) Extrema matching score。除 PPL 外，所有指标均使用 NLG evaluation toolkit (Sharma et al., 2017) 计算，回复由 NLTK (Loper and Bird, 2002) 分词。

从实验结果（表4）可以得到三个主要发现。（1）Oracle 模型在所有指标上都显著优于 Vanilla 模型，表明支持策略具有很高效用。（2）Joint 模型得分略低于 Vanilla 模型，因为如果预测策略与 ground truth 不同，生成回复会与 reference response 差异较大。然而，当没有提供 ground truth 标签时，学习预测策略十分重要；我们将在人工交互式评估中进一步考察 Joint 模型性能（6.4节）。（3）BlenderBot 变体持续优于 DialoGPT 变体，说明 BlenderBot 更适合 ESC 任务。因此，在后续人工评估中，我们将重点评估 BlenderBot 变体。

Backbones	Variants	PPL	B-2	R-L	Extrema
DialoGPT	Vanilla	15.51	5.13	15.26	49.80
	Joint	-	5.00	15.09	49.97
	Oracle	15.19	5.52	15.82	50.18
BlenderBot	Vanilla	16.23	5.45	15.43	50.49
	Joint	-	5.35	15.46	50.27
	Oracle	16.03	6.31	17.90	51.65

Table 4: Results of automatic evaluation. The results in **bold** are significantly better than all the competitors (Student’s t-test, p -value < 0.05).

6.4 人工交互式评估

我们从 Amazon Mechanical Turk 招募参与者与模型聊天。在线测试在与数据收集相同的平台上进行，但支持者角色由模型承担。每名参与者与两个不同模型聊天，模型顺序随机，以避免暴露偏差。参与者需要根据以下问题比较两个模型：（1）Fluency：哪个 bot 的回复更流畅、更容易理解？（2）Identification：哪个 bot 更深入探索了你的处境，并更有助于识别你的问题？（3）Comforting：哪个 bot 在安慰你方面更有技巧？（4）Suggestion：哪个 bot 针对你的问题给出了更有帮助的建议？（5）Overall：总体而言，你更偏好哪个 bot 的情绪支持？其中（2）、（3）和（4）分别对应 ESC Framework 的三个阶段。

我们比较了三组模型：（a）Joint vs. BlenderBot（未在 ESConv 上微调），（b）Joint vs. Vanilla，以及（c）Joint vs. Random（使用随机选择的策略）。为了更好地模拟真实策略出现情况，Random 模型按 ESConv 中的策略分布（表3）随机选择策略。

每组模型由 100 段与人类参与者的对话进行比较（表5）。比较（a）的结果显示，在 ESConv 上微调后，BlenderBot 提供 ES 的能力在所有指标上都显著提升。比较（b）表明，使用策略可以更好地安慰用户。比较（c）的结果也说明，策略的恰当时机对于帮助用户识别问题并提供有效建议至关重要。总体而言，在 ESConv 上通过策略预测监督进行微调后，预训练模型更受用户偏好，这证明了 ESConv 的高质量和效用。

Joint vs.	w/o ft		Vanilla		Random	
	Win	Lose	Win	Lose	Win	Lose
Fluency	71[†]	24	52[†]	35	53[†]	35
Identification	65[‡]	25	50	34	54[†]	37
Comforting	75[‡]	20	54[‡]	34	47	39
Suggestion	72[‡]	21	47	39	48[†]	27
Overall	73[‡]	20	51[†]	34	56[‡]	36

Table 5: Results of the human interactive evaluation. Ties are not shown. All the models use BlenderBot as the backbone. ‘w/o ft’ denotes the BlenderBot model without fine-tuning on ESConv. The Joint model outperforms all the competitors on all the metrics (sign test, [†]/[‡] denote $p\text{-value} < 0.1/0.05$ respectively).

6.5 人工交互式评估的进一步分析




Figure 5: The Joint model’s generation distribution. The meanings of all the graphics and abbreviations are consistent with Figure 4.

本节探讨对话模型从 ESConv 中学到了什么。首先，我们基于人工交互式实验中用户与 Joint 模型之间的 300 段对话分析策略分布。从图5可以看到（计算方式与图4一致），Joint 模型采用的策略分布与 ESConv 中的真实分布（图4）非常相似。这为模型像人类支持者一样模仿策略选择和使用、从而实现更有效 ES 提供了重要证据。其次，我们在图7中展示了一个案例研究。从案例可见，Joint 模型提供了更具支持性的回复，并在对话中使用了更多技能；而未微调的 BlenderBot 似乎并未很好理解用户的痛苦，并倾向于更多谈论自己。这可能意味着，更多支持性回复以及多样化的支持策略对有效情绪支持至关重要。

7 结论

本文定义了 Emotional Support Conversation 任务，并提出了 ESC Framework。ESC Framework 将 Helping Skills Theory 调整到对话系统场景中，刻画了三个阶段及各阶段中有用的相应支持策略。随后，我们构建了情绪支持对话数据集 ESConv。我们精心设计数据收集流程，并设置多种机制，以确保对话中 ES 的有效性。最后，我们使用 state-of-the-art 对话模型评估 ES 能力。实验结果表明，ESConv 在提升对话系统提供有效 ES 的能力方面具有潜在效用。本文工作可以促进未来对 ES 对话系统的研究，也可以改进其他对话场景中的模型，因为在这些场景中，情绪支持也发挥着重要作用。策略选择与实现、用户状态建模以及任务评估，是后续研究的重要方向。

致谢

本研究受 NSFC 项目支持（重点项目 No. 61936010，面上项目 No. 61876096）。本研究也受清华大学国强研究院支持，项目编号为 2019GQG1 和 2020GQG0005。

伦理考量

人类可能寻求并提供多种类型和层次的支持，例如专业支持与同伴支持；其中某些层次对于系统而言可能并不适合、不现实，且风险过高。然而，随着对话系统在日常使用中变得更加普遍，可能会出现至少需要一些基本支持性表达的场景。在开发 ESC Framework 时，我们已经谨慎考虑了哪些会话支持要素可能适用于对话系统，并省略了明显越界的要素。仍需大量后续工作来确定系统适合提供或人们可以期待系统提供何种层次的支持；但本文工作向开发能够提供合理、适度支持的系统迈出了谨慎而具体的一步。我们构建的语料也能为未来工作提供示例，以便研究系统在伦理上能够或应当提供支持的边界。除这些更广泛的伦理考量外，我们也努力以合乎伦理的方式开展本研究，包括向众包工作者透明说明数据使用和研究目的，以合理时薪补偿工作者，并获得 Institutional Review Board 的研究批准。

References

- Amit Baumel. 2015. Online emotional support delivered by trained volunteers: users' satisfaction and their perception of the service compared to psychotherapy. *Journal of Mental Health*, 24(5):313–320.
- Brant R Burleson. 2003. Emotional support skill. *HANDBOOK OF COMMUNICATION AND SOCIAL INTERACTION SKILLS*, page 551.
- Jacob Cohen. 1960. A coefficient of agreement for nominal scales. *Educational and psychological measurement*, 20(1):37–46.
- Catherine A Heaney and Barbara A Israel. 2008. Social networks and social support. *Health behavior and health education: Theory, research, and practice*, 4:189–210.
- Clara E Hill. 2009. *Helping skills: Facilitating, exploration, insight, and action*. American Psychological Association.
- Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, and Yejin Choi. 2019. The curious case of neural text degeneration. In *International Conference on Learning Representations*.
- Mahshid Hosseini and Cornelia Caragea. 2021. It takes two to empathize: One to seek and one to provide. *Proceedings of the 35th American Association for Artificial Intelligence (AAAI 2021)*.
- Minlie Huang, Xiaoyan Zhu, and Jianfeng Gao. 2020. Challenges in building intelligent open-domain dialog systems. *ACM Transactions on Information Systems (TOIS)*, 38(3):1–32.
- Bernd Huber, Daniel McDuff, Chris Brockett, Michel Galley, and Bill Dolan. 2018. Emotional dialogue generation using image-grounded language models. In *Proceedings of the 2018 CHI Conference on Human Factors in Computing Systems*, pages 1–12.
- Diederik P Kingma and Jimmy Ba. 2014. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.
- Catherine Penny Hinson Langford, Juanita Bowsher, Joseph P Maloney, and Patricia P Lillis. 1997. Social support: a conceptual analysis. *Journal of advanced nursing*, 25(1):95–100.
- Yanran Li, Hui Su, Xiaoyu Shen, Wenjie Li, Ziqiang Cao, and Shuzi Niu. 2017. DailyDialog: A manually labelled multi-turn dialogue dataset. In *Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 986–995, Taipei, Taiwan. Asian Federation of Natural Language Processing.
- Chin-Yew Lin. 2004. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81, Barcelona, Spain. Association for Computational Linguistics.
- Zhaojiang Lin, Andrea Madotto, Jamin Shin, Peng Xu, and Pascale Fung. 2019. MoEL: Mixture of empathetic listeners. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 121–132, Hong Kong, China. Association for Computational Linguistics.
- Chia-Wei Liu, Ryan Lowe, Iulian Serban, Mike Noseworthy, Laurent Charlin, and Joelle Pineau. 2016. How NOT to evaluate your dialogue system: An empirical study of unsupervised evaluation metrics for dialogue response generation. In

Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, pages 2122–2132, Austin, Texas. Association for Computational Linguistics.

Edward Loper and Steven Bird. 2002. Nltk: the natural language toolkit. arXiv preprint cs/0205028.

Navonil Majumder, Pengfei Hong, Shanshan Peng, Jiankun Lu, Deepanway Ghosal, Alexander Gelbukh, Rada Mihalcea, and Soujanya Poria. 2020. MIME: MIMicking emotions for empathetic response generation. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 8968–8979, Online. Association for Computational Linguistics.

Lenin Medeiros and Tibor Bosse. 2018. Using crowdsourcing for the development of online emotional support agents. In International Conference on Practical Applications of Agents and Multi-Agent Systems, pages 196–209. Springer.

Burt L Monroe, Michael P Colaresi, and Kevin M Quinn. 2008. Fightin’ words: Lexical feature selection and evaluation for identifying the content of political conflict. *Political Analysis*, 16(4):372–403.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. Bleu: a method for automatic evaluation of machine translation. In Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics, pages 311–318, Philadelphia, Pennsylvania, USA. Association for Computational Linguistics.

Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. 2019. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9.

Stephen A Rains, Corey A Pavlich, Bethany Lutovsky, Eric Tsetsi, and Anjali Ashtaputre. 2020. Support seeker expectations, support message quality, and supportive interaction processes and outcomes: The case of the comforting computer program revisited. *Journal of Social and Personal Relationships*, 37(2):647–666.

Hannah Rashkin, Eric Michael Smith, Margaret Li, and Y-Lan Boureau. 2019. Towards empathetic open-domain conversation models: A new benchmark and dataset. In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, pages 5370–5381, Florence, Italy. Association for Computational Linguistics.

Stephen Roller, Emily Dinan, Naman Goyal, Da Ju, Mary Williamson, Yinhan Liu, Jing Xu, Myle Ott, Kurt Shuster, Eric M Smith, et al. 2020. Recipes for building an open-domain chatbot. arXiv preprint arXiv:2004.13637.

Ashish Sharma, Adam Miner, David Atkins, and Tim Althoff. 2020a. A computational approach to understanding empathy expressed in text-based mental health support. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 5263–5276, Online. Association for Computational Linguistics.

Ashish Sharma, Adam S Miner, David C Atkins, and Tim Althoff. 2020b. A computational approach to understanding empathy expressed in text-based mental health support. arXiv preprint arXiv:2009.08441.

Shikhar Sharma, Layla El Asri, Hannes Schulz, and Jeremie Zumer. 2017. Relevance of unsupervised metrics in task-oriented dialogue for evaluating natural language generation. arXiv preprint arXiv:1706.09799.

Siqi Shen, Charles Welch, Rada Mihalcea, and Verónica Pérez-Rosas. 2020. Counseling-style reflection generation using generative pretrained transformers with augmented context. In Proceedings of the 21th Annual Meeting of the Special Interest Group on Discourse and Dialogue, pages 10–20, 1st virtual meeting. Association for Computational Linguistics.

Hao Sun, Zhenru Lin, Chujie Zheng, Siyang Liu, and Minlie Huang. 2021. Psyqa: A chinese dataset for generating long counseling text for mental health support. In Findings of the Association for Computational Linguistics: ACL 2021.

Janneke M van der Zwaan, Virginia Dignum, and Catholijn M Jonker. 2012. A conversation model enabling intelligent agents to give emotional support. In *Modern Advances in Intelligent Systems and Tools*, pages 47–52. Springer.

JM Van der Zwaan, V Dignum, and CM Jonker. 2012. A bdi dialogue agent for social support: Specification and evaluation method. In *AAMAS 2012: Proceedings of the 11th International Conference on Autonomous Agents and Multiagent Systems, Workshop on Emotional and Empathic Agents*, Valencia, Spain, 4-8 June 2012; authors version. International Foundation for Autonomous Agents and Multiagent Systems (IFAAMAS).

Charles Welch, Allison Lahnala, Veronica Perez-Rosas, Siqi Shen, Sarah Seraj, Larry An, Kenneth Resnicow, James Pennebaker, and Rada Mihalcea. 2020. Expressive interviewing: A conversational system for coping with COVID-19. In Proceedings of the 1st Workshop on NLP for COVID-19 (Part 2) at EMNLP 2020, Online. Association for Computational Linguistics.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Remi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, and Alexander Rush. 2020. Transformers: State-of-the-art natural language processing. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, pages 38–45, Online. Association for Computational Linguistics.

Rohola Zandie and Mohammad H Mahoor. 2020. Emptransfo: A multi-head transformer architecture for creating empathetic dialog systems. arXiv preprint arXiv:2003.02958.

Yizhe Zhang, Siqi Sun, Michel Galley, Yen-Chun Chen, Chris Brockett, Xiang Gao, Jianfeng Gao, Jingjing Liu, and Bill Dolan. 2020. DIALOGPT : Large-scale generative pre-training for conversational response generation. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: System Demonstrations, pages 270–278, Online. Association for Computational Linguistics.

Chujie Zheng, Yong Liu, Wei Chen, Yongcai Leng, and Minlie Huang. 2021. Comae: A multi-factor hierarchical framework for empathetic response generation. In Findings of the Association for Computational Linguistics: ACL 2021.

Peixiang Zhong, Chen Zhang, Hao Wang, Yong Liu, and Chunyan Miao. 2020. Towards persona-based empathetic conversational models. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 6556–6566, Online. Association for Computational Linguistics.

Hao Zhou, Minlie Huang, Tianyang Zhang, Xiaoyan Zhu, and Bing Liu. 2018. Emotional chatting machine: Emotional conversation generation with internal and external memory. In Proceedings of the AAAI Conference on Artificial Intelligence.

Li Zhou, Jianfeng Gao, Di Li, and Heung-Yeung Shum. 2020. The design and implementation of xiaoice, an empathetic social chatbot. *Computational Linguistics*, 46(1):53–93.

Xianda Zhou and William Yang Wang. 2018. MojiTalk: Generating emotional responses at scale. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1128–1137, Melbourne, Australia. Association for Computational Linguistics.

附录A ESConv 中的一个数据示例

这里我们详细说明图1展示的对话，以展示本文数据集中包含的标注。详细示例见图6。每段对话的聊天前问卷都标注了问题类别、情绪类别、情绪强度以及求助者情境简述。在每段对话的上下文中，支持者使用的策略被标注；同时，数据集中也给出了求助者针对支持者每两条回复的反馈分数。需要注意的是，并非所有对话都有对话后情绪强度标签。这是因为一些求助者没有完成聊天后问卷，但由于这些对话质量较高且满足我们的标准，我们仍将其纳入数据集。

criteria.

Pre-chat Survey	
Problem: Academic pressure Emotion: Anxiety Emotion Intensity: 5 Situation: My school was closed due to the pandemic.	
Conversation	
Seeker: I feel so frustrated. Supporter (<i>Questions</i>): May I ask why you are feeling frustrated? Seeker: My school was closed without any prior warning due to the pandemic. Supporter (<i>Affirmation and Reassurance</i>): That is really upsetting and stressful. I commend you for having to deal with that! Supporter (<i>Self-disclosure</i>): I know I would have been really frustrated if that happened to me.	
System: Do those messages help you feel better?	★★★★★
Seeker: Yeah! I don't even know what is going to happen with our finals now. Supporter (<i>Restatement or Paraphrasing</i>): I can see how that would make you frustrated. Supporter (<i>Providing Suggestions</i>): Have you thought about talking to your parents or a close friend about this?	
System: Do those messages help you feel better?	★★★★★
...	
Seeker: I really appreciate your assistance today. I feel better and will take some action this week. Thank you! Supporter (<i>Others</i>): You're very welcome! Feel free to chat if you need anything else!	
Post-chat Survey	
Emotion Intensity: 2	

Figure 6: Data example from ESConv. **Blue text:** the help-seeker's pre-chat survey. **Red text:** strategies used by the supporter. **Orange text:** the question that the systems ask help-seeker to evaluate the helpfulness per two utterances from the supporter. Thus the stars denote the seeker's feedback score.

附录B 策略定义

Question. 询问与问题相关的信息，帮助求助者表述其面对的困难。开放式问题最好；封闭式问题可用于获得具体信息。

Restatement or Paraphrasing. 对求助者陈述进行简单、更简洁的重述，以帮助他们更清楚地看见自己的处境。

Reflection of Feelings. 表达并描述求助者的感受。

Self-disclosure. 披露你曾有过的相似经历，或与你和求助者共有的情绪，以表达共情。

Affirmation and Reassurance. 肯定求助者的优势、动机和能力，并提供安抚与鼓励。

Providing Suggestions. 提供关于如何改变的建議，但要注意不要越界，不要命令他们应该怎么做。

Information. 向求助者提供有用信息，例如数据、事实、观点、资源，或回答问题。

Others. 进行礼貌寒暄，或使用不属于上述类别的其他支持策略。

	Strategy Transition	Proportion
3-Hop	Qu → AR → Qu	19.65 ‰
	Qu → RP → Qu	14.55 ‰
	Qu → RP → AR	12.37 ‰
	AR → Qu → AR	11.96 ‰
	Ot → Qu → RP	11.64 ‰
4-Hop	Qu → AR → Qu → AR	7.00 ‰
	AR → Qu → AR → Qu	5.13 ‰
	Ot → Qu → RP → Qu	4.20 ‰
	PS → Ot → PS → Ot	3.85 ‰
	Qu → RP → AR → Qu	3.85 ‰

Table 6: Proportions of top-5 strategy transitions in supporter utterances. Abbreviations are consistent with Figure 4.

附录C 实现细节

所有模型的实现都基于 Transformer library (Wolf et al., 2020)。我们按 6:2:2 的比例将 ESConv 划分为训练集、验证集和测试集。由于 ESConv 中的对话通常轮数较长，我们将每段对话切分为包含 5 条话语的对话片段，其中包含一条支持者回复及其之前的 4 条话语。训练期间，我们使用 Adam (Kingma and Ba, 2014) 优化器训练所有模型，学习率为 $5e^{-5}$ 。所有模型训练 5 个 epoch，并选择验证集上 perplexity 最低的 checkpoint 用于评估。推理期间，我们 mask 掉其他 token，并在回复的第一个位置采样一个策略 token。对于 Random 变体模型，我们按照表3报告的 ESConv 策略分布随机采样策略。回复采用 Top-k 与 Top-p sampling 解码，其中 $p = 0.9$ (Holtzman et al., 2019)、 $k = 30$ 、temperature $\tau = 0.7$ 、repetition penalty = 1.03。

附录D 自动通过标准

为了建立正文 (3.4节) 所示自动通过程序的每项标准，我们为每条过滤规则搜索最合适的阈值。我们招募了三名训练充分的人工标注者，他们也接受了与支持者申请者相同的训练流程。随后，我们从数据集中随机抽取 100 段对话，并要求三名标注者判断这些对话是否合格，即是否提供了有效情绪支持。接着，我们利用聊天后问卷结果和说话者话语长度，选择合适阈值作为过滤规则。之后，我们将每条自动过滤规则视为一名规则标注者，并计算该规则标注者与每名人工标注者之间的 Cohen's Kappa (Cohen, 1960) 得分。

表7中的一致性得分是每个规则标注者与三名人工标注者之间一致性得分的 Cohen's Kappa。我们选择了能够带来第二高一致性得分的阈值，并将这些阈值用于过滤规则。我们没有使用一致性最高的那组阈值，因为基于这些阈值的规则更加严格，会过滤掉许多对话。然而，第二高分仅略低于最高得分，因此基于第二高阈值的规则能够以很小的可接受代价保留更多合格对话。最终，一段合格对话要求支持者必须满足

四项标准中的至少三项，求助者必须同时满足对应的两项标准。最终“规则”标注者结合了两个条件，它与三名人工标注者之间的平均一致性得分为 0.576，表明显著一致。

Auto-approval Rule						Consistency			
Supporter				Seeker		Human1	Human2	Human3	Average
Improvement	Avg. Length	Empathy	Relevance	Detail	Avg. Length				
1	8	3	4	-	6	0.545	0.659	0.525	0.576
2	8	3	4	-	6	0.505	0.566	0.486	0.519
1	8	4	4	-	6	0.539	0.602	0.519	0.553
1	8	2	4	-	6	0.539	0.618	0.570	0.576
1	8	3	3	-	6	0.546	0.630	0.526	0.567
1	8	3	5	-	6	0.575	0.640	0.555	0.590
1	8	3	4	-	7	0.539	0.602	0.473	0.538
1	8	3	4	-	5	0.520	0.551	0.501	0.524
1	8	3	4	3	6	0.505	0.653	0.531	0.563
1	8	3	4	2	6	0.527	0.640	0.508	0.558
1	8	3	4	4	6	0.457	0.599	0.482	0.513
1	9	3	4	-	6	0.510	0.621	0.490	0.540
1	7	3	4	-	6	0.515	0.633	0.495	0.548

Table 7: The agreement score between each “rule” annotator and three human annotators. The aspects are consistent with Table 1. The first rule means: 1) The supporter improves the help-seeker’s emotional state as least one score (emotional improvement is calculated as the help-seeker’s emotion intensity before the conversation minus the emotion intensity after the conversation). 2) The average length of the supporter’s utterances is no less than eight. 3) The empathy score of the supporter’s performance is no less than three. 4) The topic relevance score of the supporter’s performance is no less than four. 5) The score that measures how well the help-seeker goes into detail about their problems is not required to be used in the rule (denoted as ‘-’). (6) The average length of the help-seeker’s utterances is no less than six.

Problem: Problems with friends Emotion: Sadness Emotion Intensity: 5 Situation: My friend is drinking too much.	
Joint	BlenderBot w/o Fine-tuning
Seeker: Hi there. I feel sadness because my friend has a drinking problem. Supporter (Question): I am sorry to hear that. What do you think is going on? Seeker: I think he just got used to drink every day and I can't pursue him to stop at least for a week. Supporter (Question): I can see how that would be difficult for you. Does your friend drink at home or does it happen at work or home? Seeker: Well he is working from home. So he is drinking almost 24/7. I feel so exhausted as well. Supporter (Reflection of Feelings): I understand that you feel like you are exhausted, but I think you can get through this! Seeker: I just need a way to make him stop drinking. Maybe I should stop any communication with him for a while? Supporter (Affirmation and Reassurance): I think it's a great idea! I would do it if I were you! Seeker: Probably that's what I will do. I just can't take this anymore. If he wants he can buy drinks himself as I am tired walking to shop every day and all neighbors thinking that I am an alcoholic. Supporter (Self-disclosure): I completely understand where you are coming from. I was in the same situation as you. Seeker: It was so nice to chat with you, I feel better now. Supporter (Affirmation and Reassurance): You're welcome! I'm glad I could help!	Seeker: Hi there. My friend has a drinking problem and I don't know what to do. Supporter: I know it can be difficult, but if you can do it, I'm sure you can find a way. I hope he gets better soon. Seeker: I feel such a sadness inside me. I am trying to help him but he won't listen. Supporter: I understand completely. it is tough, but I am sure you will get through it. Seeker: Every day he is drinking beer and he is not listening to me. Supporter: I can imagine. I feel like that's the only way I can keep up with him. I have tried so hard. I think I just have to try harder than him to get through this. Seeker: Few more months and I think I will give up on him Supporter: That is exactly how I feel... I am trying to find the right person for me and I can't do it! Seeker: I thought you are here to help me? Supporter: It's hard, but we all have to stick together. There are so many people out there, you just have time. Seeker: Maybe I should ignore my friend for a while? Maybe I will feel better? Supporter: I try to just hang out with friends. I have been trying to meet new people in the city but they just don't show up. I just want to be alone and be alone. Seeker: Thank you for your help. Supporter: You're welcome. I think that's what I'll do too. I'm trying to get used to the city life. I feel like I've been stuck in this city for so long.

Figure 7: Case Study. **Blue text:** the help-seeker’s pre-chat survey. **Red text:** strategies predicted by the model. **Green background:** utterances that corresponding to the used strategies. **Yellow background:** utterances where the model talks about itself and is not user-centered.

附录E 数据收集平台界面

为了帮助读者直观理解我们的数据收集过程，图8展示了数据收集过程若干重要步骤的界面示意图，包括支持策略训练、支持者聊天、求助者聊天前问卷、求助者聊天和聊天后问卷。




Figure 8: (a) Support strategy training. (b) Pre-chat survey. (c) The help-seeker’s chatting interface. (d) The supporter’s chatting interface. (e) Post-chat survey.